



ΕΘΝΙΚΟ ΜΕΤΣΟΒΙΟ ΠΟΛΥΤΕΧΝΕΙΟ  
ΣΧΟΛΗ ΕΦΑΡΜΟΣΜΕΝΩΝ ΜΑΘΗΜΑΤΙΚΩΝ ΚΑΙ ΦΥΣΙΚΩΝ  
ΕΠΙΣΤΗΜΩΝ  
ΔΙΠΜΣ ΣΤΗΝ ΜΑΘΗΜΑΤΙΚΗ ΠΡΟΤΥΠΟΠΟΙΗΣΗ ΣΕ ΣΥΓΧΡΟΝΕΣ  
ΤΕΧΝΟΛΟΓΙΕΣ ΚΑΙ ΣΤΗΝ ΧΡΗΜΑΤΟΟΙΚΟΝΟΜΙΚΗ

# Μπεϋζιανή Στατιστική και MCMC

## Εργασία Εξαμήνου

**Διδάσκων:**

Δημήτριος Φουσκάκης

**Αντωνία Κατσούρη**

ΑΜ: 09325010

antoniakatsouri1@gmail.com

ΙΟΥΝΙΟΣ 2026

## Περιεχόμενα

|                     |           |
|---------------------|-----------|
| <b>Άσκηση 1</b>     | <b>3</b>  |
| Ερώτημα Α . . . . . | 3         |
| Ερώτημα Β . . . . . | 5         |
| Ερώτημα Γ . . . . . | 8         |
| Ερώτημα Δ . . . . . | 22        |
| <b>Άσκηση 2</b>     | <b>25</b> |
| Ερώτημα Α . . . . . | 25        |
| Ερώτημα Β . . . . . | 27        |
| <b>Άσκηση 3</b>     | <b>29</b> |
| <b>Άσκηση 4</b>     | <b>38</b> |

# Άσκηση 1

## Ερώτημα Α

Θεωρούμε το πολλαπλό γραμμικό μοντέλο για  $n$  παρατηρήσεις και  $k$  επεξηγηματικές μεταβλητές:

$$Y = X\beta + \varepsilon$$

όπου  $Y, \varepsilon \in \mathbb{R}^n$  και  $\beta \in \mathbb{R}^p$  (με  $p = k + 1$ ). Τα διανύσματα του μοντέλου ορίζονται ως:

$$\begin{aligned} y &= (y_1, \dots, y_n)^T \in \mathbb{R}^n && : \text{το διάνυσμα των } n \text{ παρατηρήσεων} \\ X &= \begin{pmatrix} 1 & x_{11} & \dots & x_{1k} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & \dots & x_{nk} \end{pmatrix} \in \mathbb{R}^{n \times p} && : \text{ο πίνακας σχεδιασμού } (n \times p) \\ \beta &= (\beta_0, \beta_1, \dots, \beta_k)^T \in \mathbb{R}^p && : \text{το διάνυσμα των } p \text{ παραμέτρων} \\ \varepsilon &= (\varepsilon_1, \dots, \varepsilon_n)^T \in \mathbb{R}^n && : \text{το διάνυσμα των } n \text{ σφαλμάτων} \end{aligned}$$

Γνωρίζουμε ότι οι επεξηγηματικές μεταβλητές προέρχονται από την πολυδιάστατη κανονική κατανομή με μέση τιμή  $\mathbf{0}$  και πίνακα συνδιακύμανσης τον ταυτοτικό.

Επομένως:

$$\varepsilon \sim N_n(\mathbf{0}, \sigma^2 I_n)$$

Στο μοντέλο μας  $y = X\beta + \varepsilon$ , έχουμε λόγω της γραμμικότητας:

$$E(y \mid X, \beta, \sigma^2) = E(X\beta + \varepsilon \mid X, \beta, \sigma^2) = X\beta + 0 = X\beta$$

$$\text{Var}(y \mid X, \beta, \sigma^2) = \text{Var}(X\beta + \varepsilon \mid X, \beta, \sigma^2) = 0 + \text{Var}(\varepsilon) = \sigma^2 I_n$$

Δηλαδή  $y \mid X, \beta, \sigma^2 \sim N_n(X\beta, \sigma^2 I_n)$ .

Βλέπουμε λοιπόν ότι δεδομένου ότι το σφάλμα  $\varepsilon$  ακολουθεί την πολυδιάστατη κανονική κατανομή  $N_n(\mathbf{0}, \sigma^2 I_n)$  και το διάνυσμα  $X\beta$  αποτελεί μια μετατόπιση του τυχαίου αυτού σφάλματος, το διάνυσμα των παρατηρήσεων  $y = X\beta + \varepsilon$  ακολουθεί επίσης πολυδιάστατη κανονική κατανομή με αναμενόμενη τιμή  $E[y] = X\beta$  και τον ίδιο πίνακα συνδιακύμανσης  $\text{Var}(y) = \sigma^2 I_n$ .

Η συνάρτηση πυκνότητας πιθανότητας της πολυδιάστατης κανονικής κατανομής ορίζει τη συνάρτηση πιθανοφάνειας:

$$\ell(\beta, \sigma^2 \mid y, X) = \frac{1}{(2\pi)^{n/2} |\sigma^2 I_n|^{1/2}} \exp \left[ -\frac{1}{2} (y - X\beta)^T (\sigma^2 I_n)^{-1} (y - X\beta) \right]$$

### σχέση (1)

όπου

$$\sigma^2 I_n = \begin{pmatrix} \sigma^2 & 0 & & \\ 0 & \sigma^2 & & \\ & & \ddots & 0 \\ & & 0 & \sigma^2 \end{pmatrix} \quad \text{άρα} \quad |\sigma^2 I_n| = (\sigma^2)^n$$

και

$$(\sigma^2 I_n)^{-1} = \frac{1}{\sigma^2} I_n$$

Εδώ χρησιμοποιήσαμε ότι για έναν πίνακα  $A$  διάστασης  $n \times n$  και βαθμωτό  $k$ , ισχύει  $|kA| = k^n |A|$ .

Άρα,

$$\begin{aligned}\ell(\beta, \sigma^2 | y, X) &= \frac{1}{(2\pi)^{n/2}(\sigma^2)^{n/2}} \exp \left[ -\frac{1}{2}(y - X\beta)^T \frac{1}{\sigma^2} I_n (y - X\beta) \right] \\ &= (2\pi\sigma^2)^{-\frac{n}{2}} \exp \left[ -\frac{1}{2\sigma^2}(y - X\beta)^T (y - X\beta) \right]\end{aligned}$$

Εισάγουμε τον εκτιμητή ελαχίστων τετραγώνων

$$\hat{\beta} = (X^T X)^{-1} X^T y$$

Γράφουμε:

$$\begin{aligned}y - X\beta &= y - X\hat{\beta} + X\hat{\beta} - X\beta \\ &= y - X\hat{\beta} + X(\hat{\beta} - \beta)\end{aligned}$$

Επομένως το γινόμενο  $(y - X\beta)^T (y - X\beta)$  γίνεται:

$$\begin{aligned}(y - X\beta)^T (y - X\beta) &= \left[ y - X\hat{\beta} + X(\hat{\beta} - \beta) \right]^T \left[ y - X\hat{\beta} + X(\hat{\beta} - \beta) \right] \\ &= \left\{ (y - X\hat{\beta})^T + \left[ X(\hat{\beta} - \beta) \right]^T \right\} \left[ y - X\hat{\beta} + X(\hat{\beta} - \beta) \right] \\ &= (y - X\hat{\beta})^T (y - X\hat{\beta}) + (y - X\hat{\beta})^T X(\hat{\beta} - \beta) \\ &\quad + \left[ X(\hat{\beta} - \beta) \right]^T (y - X\hat{\beta}) + \left[ X(\hat{\beta} - \beta) \right]^T X(\hat{\beta} - \beta) \\ &= (y - X\hat{\beta})^T (y - X\hat{\beta}) + 2 \left[ X(\hat{\beta} - \beta) \right]^T (y - X\hat{\beta}) \\ &\quad + (\hat{\beta} - \beta)^T (X^T X)(\hat{\beta} - \beta)\end{aligned}$$

### [σχέση (2)]

Εδώ χρησιμοποιήσαμε τις ιδιότητες του ανάστροφου πίνακα  $(A+B)^T = A^T + B^T$  και  $(AB)^T = B^T A^T$  καθώς επίσης την επιμεριστική ιδιότητα του πολλαπλασιασμού πινάκων.

Τώρα, θα δείξουμε ότι  $(y - X\hat{\beta})^T X(\hat{\beta} - \beta) = 0$  και αντίστοιχα για το  $2(y - X\hat{\beta})^T X(\hat{\beta} - \beta) = 0$ . Αναπτύσσουμε το γινόμενο  $(y - X\hat{\beta})^T X$ :

$$(y - X\hat{\beta})^T X = y^T X - (X\hat{\beta})^T X = y^T X - \hat{\beta}^T X^T X$$

Αντικαθιστούμε τον ορισμό του  $\hat{\beta} = (X^T X)^{-1} X^T y$  στην παράσταση  $\hat{\beta}^T X^T X$ :

$$\begin{aligned}\hat{\beta}^T X^T X &= \left[ (X^T X)^{-1} X^T y \right]^T X^T X \\ &= y^T X \left[ (X^T X)^{-1} \right]^T X^T X \\ &= y^T X (X^T X)^{-1} X^T X\end{aligned}$$

Επειδή  $(X^T X)^{-1} X^T X = I$  (ο ταυτοτικός πίνακας), η σχέση απλοποιείται σε:

$$\hat{\beta}^T X^T X = y^T X$$

Συνεπώς:

$$(y - X\hat{\beta})^T X = y^T X - y^T X = 0$$

Αφού ο πρώτος παράγοντας του μεσαίου όρου είναι το μηδενικό διάνυσμα, ολόκληρος ο μεσαίος όρος εκμηδενίζεται:

$$2(y - X\hat{\beta})^T X(\hat{\beta} - \beta) = 0$$

Ορίζουμε το άθροισμα τετραγώνων των καταλοίπων ως  $s^2 = (y - X\hat{\beta})^T (y - X\hat{\beta})$ .  
 Η σχέση (2) γίνεται:

$$(y - X\beta)^T (y - X\beta) = s^2 + (\hat{\beta} - \beta)^T X^T X (\hat{\beta} - \beta)$$

Ισχύει ότι ο πίνακας  $X^T X$  είναι συμμετρικός και η τετραγωνική μορφή δεν αλλάζει αν αντιστρέψουμε τη σειρά αφαίρεσης μέσα στην παρένθεση, δηλαδή:

$$\begin{aligned} (\beta - \hat{\beta})^T A (\beta - \hat{\beta}) &= [-(\hat{\beta} - \beta)]^T A [-(\hat{\beta} - \beta)] \\ &= (-1)(\hat{\beta} - \beta)^T A \cdot (-1)(\hat{\beta} - \beta) \\ &= (-1)^2 (\hat{\beta} - \beta)^T A (\hat{\beta} - \beta) \\ &= (\hat{\beta} - \beta)^T A (\hat{\beta} - \beta) \end{aligned}$$

$$(\hat{\beta} - \beta)^T X^T X (\hat{\beta} - \beta) = (\beta - \hat{\beta})^T X^T X (\beta - \hat{\beta})$$

Αντικαθιστώντας αυτό το αποτέλεσμα πίσω στη συνάρτηση πιθανοφάνειας σχέση (1), λαμβάνουμε την τελική ζητούμενη μορφή:

$$\ell(\beta, \sigma^2 \mid y, X) = (2\pi\sigma^2)^{-\frac{n}{2}} \exp \left[ -\frac{1}{2\sigma^2} s^2 - \frac{1}{2\sigma^2} (\beta - \hat{\beta})^T (X^T X) (\beta - \hat{\beta}) \right]$$

■

Σημειώνουμε ότι το μοντέλο που εξετάζουμε στην άσκηση είναι το πολλαπλό γραμμικό μοντέλο:

$$Y = X\beta + \varepsilon$$

όπου  $X$  είναι ο πίνακας σχεδιασμού διάστασης  $50 \times 16$ , και:

$$\begin{aligned} y &= \begin{pmatrix} y_1 \\ \vdots \\ y_{50} \end{pmatrix} : \text{το διάνυσμα των 50 παρατηρήσεων} \\ \beta &= \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_{15} \end{pmatrix} : \text{το διάνυσμα των παραμέτρων προς εκτίμηση} \\ \varepsilon &= \begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_{50} \end{pmatrix} : \text{το τυχαίο σφάλμα για κάθε παρατήρηση} \end{aligned}$$

## Ερώτημα Β

Συμβολίζουμε  $\pi(\cdot)$  τις συναρτήσεις πυκνότητας πιθανότητας τυχαίων μεταβλητών που αποτελούν παραμέτρους του μοντέλου.

Σύμφωνα με το θεώρημα του Bayes, η από κοινού ύστερη κατανομή των παραμέτρων  $\beta$  και  $\sigma^2$  είναι ανάλογη του γινομένου της συνάρτησης πιθανοφάνειας επί τις πρότερες κατανομές (priors):

$$\pi(\beta, \sigma^2 \mid y, X) \propto \ell(\beta, \sigma^2 \mid y, X) \times \pi(\beta \mid \sigma^2) \times \pi(\sigma^2)$$

Συνοψίζουμε τα εξής:

Πιθανοφάνεια (Likelihood):

$$\ell(\beta, \sigma^2 \mid y, X) = (2\pi\sigma^2)^{-\frac{n}{2}} \exp \left[ -\frac{1}{2\sigma^2} s^2 - \frac{1}{2\sigma^2} (\beta - \hat{\beta})^T (X^T X) (\beta - \hat{\beta}) \right]$$

Πρότερη κατανομή του  $\beta \mid \sigma^2$ :

$$\pi(\beta \mid \sigma^2) = (2\pi\sigma^2)^{-\frac{p}{2}} |M|^{\frac{1}{2}} \exp \left[ -\frac{1}{2\sigma^2} \beta^T M \beta \right]$$

Πρότερη κατανομή του  $\sigma^2$ :

$$\pi(\sigma^2) \propto (\sigma^2)^{-(a+1)} \exp \left[ -\frac{b}{\sigma^2} \right], \quad \text{όπου } a = 0.0001, b = 0.0001$$

Συγκεντρώνουμε τους όρους που βρίσκονται έξω από τη συνάρτηση του εκθέτη και υπολογίζουμε:

$$(\sigma^2)^{-\frac{n}{2}} \cdot (\sigma^2)^{-\frac{p}{2}} \cdot (\sigma^2)^{-a-1} = (\sigma^2)^{-\frac{n}{2} - \frac{p}{2} - a - 1}$$

Συγκεντρώνουμε όλους τους επιμέρους όρους του εκθέτη που προκύπτουν από τη συνάρτηση πιθανοφάνειας και τις πρότερες κατανομές, εκφράζοντάς τους ως ένα ενιαίο γινόμενο εκθετικών παραγόντων:

$$\exp \left[ -\frac{1}{\sigma^2} \left( b + \frac{s^2}{2} \right) - \frac{1}{2\sigma^2} \left( (\beta - \hat{\beta})^T (X^T X) (\beta - \hat{\beta}) + \beta^T M \beta \right) \right]$$

Για τη διευκόλυνση των επόμενων πράξεων, ορίζουμε το εσωτερικό της παρένθεσης ως μια νέα παράσταση, την οποία συμβολίζουμε με το γράμμα  $\Phi$ :

$$\Phi = (\beta - \hat{\beta})^T (X^T X) (\beta - \hat{\beta}) + \beta^T M \beta$$

Τελικά η από κοινού ύστερη κατανομή γράφεται:

$$\pi(\beta, \sigma^2 \mid y, X) \propto (\sigma^2)^{-\frac{n}{2} - \frac{p}{2} - a - 1} \exp \left[ -\frac{1}{\sigma^2} \left( b + \frac{s^2}{2} \right) - \frac{1}{2\sigma^2} \Phi \right]$$

Στην συνέχεια, αναπτύσσουμε τον πρώτο όρο του  $\Phi$ :

$$(\beta - \hat{\beta})^T (X^T X) (\beta - \hat{\beta}) = \beta^T (X^T X) \beta - \beta^T (X^T X) \hat{\beta} - \hat{\beta}^T (X^T X) \beta + \hat{\beta}^T (X^T X) \hat{\beta}$$

Επειδή το  $\beta^T (X^T X) \hat{\beta}$  είναι αριθμός, ισούται με τον ανάστροφό του, δηλαδή  $\beta^T (X^T X) \hat{\beta} = \hat{\beta}^T (X^T X) \beta$ .

Επομένως, ομαδοποιώντας τους όρους ως προς  $\beta$ , η παράσταση  $\Phi$  διαμορφώνεται ως εξής:

$$\begin{aligned} \Phi &= \beta^T (X^T X) \beta - 2\hat{\beta}^T (X^T X) \beta + \hat{\beta}^T (X^T X) \hat{\beta} + \beta^T M \beta \\ &= \beta^T (M + X^T X) \beta - 2\hat{\beta}^T (X^T X) \beta + \hat{\beta}^T (X^T X) \hat{\beta} \end{aligned}$$

Έχουμε την ταυτότητα συμπλήρωσης τετραγώνου από την εκφώνηση:

$$\begin{aligned} \beta^T (M + X^T X) \beta - 2\hat{\beta}^T (X^T X) \beta &= \left( \beta - (M + X^T X)^{-1} (X^T X) \hat{\beta} \right)^T (M + X^T X) \\ &\quad \times \left( \beta - (M + X^T X)^{-1} (X^T X) \hat{\beta} \right) \\ &\quad - \hat{\beta}^T (X^T X) (M + X^T X)^{-1} (X^T X) \hat{\beta} \end{aligned}$$

Αντικαθιστώντας στην  $\Phi$  έχουμε:

$$\begin{aligned}\Phi = & \left( \beta - (M + X^T X)^{-1} (X^T X) \hat{\beta} \right)^T (M + X^T X) \left( \beta - (M + X^T X)^{-1} (X^T X) \hat{\beta} \right) \\ & - \hat{\beta}^T (X^T X) (M + X^T X)^{-1} (X^T X) \hat{\beta} \\ & + \hat{\beta}^T (X^T X) \hat{\beta}\end{aligned}$$

Ορίζουμε ως  $\beta_{post} = (M + X^T X)^{-1} (X^T X) \hat{\beta}$  την ύστερη μέση τιμή του διανύσματος των παραμέτρων. Αντικαθιστώντας αυτή την ταυτότητα στην παράσταση του  $\Phi$ , λαμβάνουμε:

$$\Phi = (\beta - \beta_{post})^T (M + X^T X) (\beta - \beta_{post}) + \hat{\beta}^T (X^T X) \hat{\beta} - \hat{\beta}^T (X^T X) (M + X^T X)^{-1} (X^T X) \hat{\beta}$$

### [σχέση (3)]

Για να απλοποιήσουμε τους δύο τελευταίους όρους της παράστασης  $\Phi$ , χρησιμοποιούμε την ταυτότητα αναστροφής πινάκων:

$$(M + X^T X)^{-1} = (X^T X)^{-1} - (X^T X)^{-1} (M^{-1} + (X^T X)^{-1})^{-1} (X^T X)^{-1}$$

Πολλαπλασιάζουμε τη σχέση αυτή από αριστερά με το διάνυσμα  $\hat{\beta}^T (X^T X)$  και από δεξιά με το  $(X^T X) \hat{\beta}$ :

$$\begin{aligned}\hat{\beta}^T (X^T X) (M + X^T X)^{-1} (X^T X) \hat{\beta} = & \hat{\beta}^T \underbrace{(X^T X) (X^T X)^{-1}}_I (X^T X) \hat{\beta} \\ & - \hat{\beta}^T \underbrace{(X^T X) (X^T X)^{-1}}_I (M^{-1} + (X^T X)^{-1})^{-1} \underbrace{(X^T X)^{-1} (X^T X)}_I \hat{\beta}\end{aligned}$$

Λόγω της απλοποίησης των ταυτοτικών πινάκων  $I$ , η παραπάνω έκφραση παίρνει τη μορφή:

$$\hat{\beta}^T (X^T X) (M + X^T X)^{-1} (X^T X) \hat{\beta} = \hat{\beta}^T (X^T X) \hat{\beta} - \hat{\beta}^T (M^{-1} + (X^T X)^{-1})^{-1} \hat{\beta}$$

Αντικαθιστώντας αυτό το αποτέλεσμα στη [σχέση (3)], παρατηρούμε ότι ο όρος  $\hat{\beta}^T (X^T X) \hat{\beta}$  απαλείφεται πλήρως:

$$\begin{aligned}\hat{\beta}^T (X^T X) \hat{\beta} - \left[ \hat{\beta}^T (X^T X) \hat{\beta} - \hat{\beta}^T (M^{-1} + (X^T X)^{-1})^{-1} \hat{\beta} \right] \\ = \hat{\beta}^T (M^{-1} + (X^T X)^{-1})^{-1} \hat{\beta}\end{aligned}$$

Συνεπώς, η τελική, απλοποιημένη μορφή του  $\Phi$ :

$$\Phi = (\beta - \beta_{post})^T (M + X^T X) (\beta - \beta_{post}) + \hat{\beta}^T (M^{-1} + (X^T X)^{-1})^{-1} \hat{\beta}$$

Για να προσδιορίσουμε την ύστερη δεσμευμένη κατανομή του  $\beta$  δεδομένου του  $\sigma^2$ , απομονώνουμε στην από κοινού ύστερη κατανομή τους όρους που περιέχουν το  $\beta$ , αντιμετωπίζοντας τη διακύμανση  $\sigma^2$  ως σταθερά:

$$\pi(\beta \mid \sigma^2, y, X) \propto \exp \left[ -\frac{1}{2\sigma^2} (\beta - \beta_{post})^T (M + X^T X) (\beta - \beta_{post}) \right]$$

Ο εκθέτης αυτός αποτελεί τον τυπικό πυρήνα μιας πολυδιάστατης Κανονικής κατανομής διάστασης  $k = 16$ . Συνεπώς, αποδείχθηκε ότι:

$$\beta \mid (\sigma^2, y, X) \sim N_{16} \left( (M + X^T X)^{-1} (X^T X) \hat{\beta}, \sigma^2 (M + X^T X)^{-1} \right)$$

Για να εξάγουμε την περιθώρια ύστερη κατανομή του  $\sigma^2$ , ολοκληρώνουμε την από κοινού ύστερη κατανομή ως προς το διάνυσμα  $\beta$  σε όλο το πεδίο ορισμού του  $\mathbb{R}^{16}$ :

$$\pi(\sigma^2 | y, X) = \int_{\mathbb{R}^k} \pi(\beta, \sigma^2 | y, X) d\beta$$

Αναπτύσσοντας το ολοκλήρωμα με βάση τις εκφράσεις που υπολογίσαμε, έχουμε:

$$\begin{aligned} \pi(\sigma^2 | y, X) &\propto (\sigma^2)^{-\frac{n}{2}-\frac{k}{2}-a-1} \exp \left[ -\frac{1}{\sigma^2} \left( b + \frac{s^2}{2} + \frac{\hat{\beta}^T (M^{-1} + (X^T X)^{-1})^{-1} \hat{\beta}}{2} \right) \right] \\ &\times \int_{\mathbb{R}^k} \exp \left[ -\frac{1}{2\sigma^2} (\beta - \beta_{post})^T (M + X^T X) (\beta - \beta_{post}) \right] d\beta \end{aligned}$$

Το ορισμένο ολοκλήρωμα ως προς  $\beta$  ισούται με τη σταθερά κανονικοποίησης της αντίστοιχης πολυδιάστατης Κανονικής κατανομής, η οποία είναι ανάλογη της ορίζουσας του πίνακα συνδιακύμανσης:

$$|\sigma^2 (M + X^T X)^{-1}|^{\frac{1}{2}} = (\sigma^2)^{\frac{k}{2}} |M + X^T X|^{-\frac{1}{2}}$$

Αντικαθιστώντας αυτή τη σταθερά πίσω στη σχέση, οι δυνάμεις του  $(\sigma^2)^{\frac{k}{2}}$  και  $(\sigma^2)^{-\frac{k}{2}}$  απλοποιούνται πλήρως:

$$\pi(\sigma^2 | y, X) \propto (\sigma^2)^{-\frac{n}{2}-a-1} \exp \left[ -\frac{1}{\sigma^2} \left( b + \frac{s^2}{2} + \frac{\hat{\beta}^T (M^{-1} + (X^T X)^{-1})^{-1} \hat{\beta}}{2} \right) \right]$$

Ομαδοποιώντας τους όρους του εκθέτη, η τελική μορφή της συνάρτησης πυκνότητας είναι:

$$\pi(\sigma^2 | y, X) \propto (\sigma^2)^{-(\frac{n}{2}+a)-1} \exp \left[ -\frac{1}{\sigma^2} \left( b + \frac{s^2}{2} + \frac{\hat{\beta}^T (M^{-1} + (X^T X)^{-1})^{-1} \hat{\beta}}{2} \right) \right]$$

Η παραπάνω έκφραση αναγνωρίζεται άμεσα ως ο πυρήνας μιας Αντίστροφης Gamma (Inverse Gamma - IG) κατανομής με τις ακόλουθες παραμέτρους:

$$\text{Παράμετρος Σχήματος (shape): } \alpha^* = \frac{n}{2} + a$$

$$\text{Παράμετρος Κλίμακας (scale): } b^* = b + \frac{s^2}{2} + \frac{\hat{\beta}^T (M^{-1} + (X^T X)^{-1})^{-1} \hat{\beta}}{2}$$

Συνεπώς,

$$\sigma^2 | (y, X) \sim IG \left( \frac{n}{2} + a, b + \frac{s^2}{2} + \frac{\hat{\beta}^T (M^{-1} + (X^T X)^{-1})^{-1} \hat{\beta}}{2} \right)$$

■

## Ερώτημα Γ

Ο πλήρης κώδικας σε περιβάλλον R για την προσομοίωση των δεδομένων, την κλασική στατιστική εκτίμηση (OLS) και τη Μπεϋζιανή ανάλυση μέσω του προγράμματος JAGS παρατίθεται παρακάτω:

```

library(MASS)
library(rjags)
library(lattice)
library(coda)

set.seed(123)
n <- 50
p <- 15

mean_vec <- rep(0, 10)
sigma_mat <- diag(10)
X_1_10 <- mvrnorm(n = n, mu = mean_vec, Sigma = sigma_mat)

X <- matrix(NA, nrow = n, ncol = p + 1)
X[, 1] <- 1
X[, 2:11] <- X_1_10

for(i in 1:n) {
  mu_x <- 0.3*X[i,2] + 0.5*X[i,3] + 0.7*X[i,4] + 0.9*X[i,5]
  + 1.5*X[i,6]
  for(j in 12:16) {
    X[i, j] <- rnorm(1, mean = mu_x, sd = 1)
  }
}

Y <- rep(NA, n)
for(i in 1:n) {
  mu_y <- 4 + 2*X[i,2] - X[i,6] + 1.5*X[i,8] + X[i,12] + 0.5*X[i,14]
  Y[i] <- rnorm(1, mean = mu_y, sd = 2.5)
}

true_betas <- c(4, 2, 0, 0, 0, -1, 0, 1.5, 0, 0, 0, 1, 0, 0.5, 0, 0)

ols_model <- lm(Y ~ X - 1)
ols_summary <- summary(ols_model)

jags_model_string <- "
model {
  for (i in 1:n) {
    Y[i] ~ dnorm(mu[i], tau)
    mu[i] <- inprod(X[i,], beta[])
  }
  for (j in 1:16) {
    beta[j] ~ dnorm(0, tau * 0.0001)
  }
  tau ~ dgamma(0.0001, 0.0001)

```

```

    sigma2 <- 1 / tau
  }
"

model <- jags.model(
  textConnection(jags_model_string),
  data      = list(Y = Y, X = X, n = n),
  n.chains = 2
)
update(model, 2000)

samples <- coda.samples(
  model      = model,
  variable.names = c("beta", "sigma2"),
  n.iter     = 10000
)

samples_matrix <- as.matrix(samples)
param_names    <- colnames(samples_matrix)
beta_idx       <- grep("^beta", param_names)
sigma2_idx     <- grep("^sigma2", param_names)

n_params <- length(param_names)
params_per_page <- 4

for(start in seq(1, n_params, by = params_per_page)) {
  end <- min(start + params_per_page - 1, n_params)
  idx <- start:end

  png(sprintf("trace_plot_%02d_%02d.png", start, end),
    width = 1200, height = 800, res = 120)
  par(mfrow = c(2, 2), mar = c(4, 4, 3, 1))
  for(k in idx) {
    chain1 <- samples[[1]][, k]
    chain2 <- samples[[2]][, k]
    ylim   <- range(c(chain1, chain2))
    plot(chain1, type = "l", col = "steelblue",
      main = paste("Trace:", param_names[k]),
      xlab = "Iteration", ylab = "Value", ylim = ylim)
    lines(chain2, col = "tomato")
    legend("topright", legend = c("Chain 1", "Chain 2"),
      col = c("steelblue", "tomato"), lty = 1, cex = 0.7)
  }
  dev.off()
}
cat("Trace plots αποθηκεύτηκαν.\n")

```

```

for(start in seq(1, n_params, by = params_per_page)) {
  end <- min(start + params_per_page - 1, n_params)
  idx <- start:end

  png(sprintf("density_plot_%02d_%02d.png", start, end),
        width = 1200, height = 800, res = 120)
  par(mfrow = c(2, 2), mar = c(4, 4, 3, 1))
  for(k in idx) {
    chain1 <- density(samples[[1]][, k])
    chain2 <- density(samples[[2]][, k])
    xlim <- range(c(chain1$x, chain2$x))
    ylim <- range(c(chain1$y, chain2$y))
    plot(chain1, col = "steelblue", lwd = 2,
          main = paste("Density:", param_names[k]),
          xlab = "Value", xlim = xlim, ylim = ylim)
    lines(chain2, col = "tomato", lwd = 2)
    legend("topright", legend = c("Chain 1", "Chain 2"),
           col = c("steelblue", "tomato"), lty = 1, cex = 0.7)
  }
  dev.off()
}
cat("Density plots αποθηκεύτηκαν.\n")

for(start in seq(1, n_params, by = params_per_page)) {
  end <- min(start + params_per_page - 1, n_params)
  idx <- start:end

  png(sprintf("autocorr_plot_%02d_%02d.png", start, end),
        width = 1200, height = 800, res = 120)
  par(mfrow = c(2, 2), mar = c(4, 4, 3, 1))
  for(k in idx) {
    ac <- autocorr(samples[[1]][, k], lags = 0:50)
    barplot(as.vector(ac), names.arg = 0:50,
            main = paste("ACF:", param_names[k]),
            xlab = "Lag", ylab = "Autocorrelation",
            col = "steelblue", border = NA,
            ylim = c(-0.2, 1))
    abline(h = 0, col = "black")
    abline(h = c(-0.1, 0.1), col = "red", lty = 2)
  }
  dev.off()
}
cat("Autocorrelation plots αποθηκεύτηκαν.\n")

```

```

for(start in seq(1, n_params, by = params_per_page)) {
  end <- min(start + params_per_page - 1, n_params)
  idx <- start:end

  png(sprintf("running_quantiles_%02d_%02d.png", start, end),
        width = 1200, height = 800, res = 120)
  par(mfrow = c(2, 2), mar = c(4, 4, 3, 1))
  for(k in idx) {
    chain <- as.vector(samples[[1]][, k])
    iters <- seq_along(chain)
    q025 <- cumsum(chain) / iters # placeholder via median
    q025 <- sapply(iters, function(t) quantile(chain[1:t], 0.025))
    q500 <- sapply(iters, function(t) quantile(chain[1:t], 0.500))
    q975 <- sapply(iters, function(t) quantile(chain[1:t], 0.975))
    ylim <- range(c(q025, q975))
    plot(iters, q500, type = "l", col = "black", lwd = 2,
         main = paste("Running Quantiles:", param_names[k]),
         xlab = "Iteration", ylab = "Value", ylim = ylim)
    lines(iters, q025, col = "steelblue", lty = 2)
    lines(iters, q975, col = "tomato", lty = 2)
    legend("topright", legend = c("2.5%", "50%", "97.5%"),
          col = c("steelblue", "black", "tomato"),
          lty = c(2, 1, 2), cex = 0.7)
  }
  dev.off()
}
cat("Running quantiles αποθηκεύτηκαν.\n")

for(start in seq(1, n_params, by = params_per_page)) {
  end <- min(start + params_per_page - 1, n_params)
  idx <- start:end

  png(sprintf("boxplot_%02d_%02d.png", start, end),
        width = 1200, height = 800, res = 120)
  par(mfrow = c(2, 2), mar = c(4, 4, 3, 1))
  for(k in idx) {
    boxplot(samples_matrix[, k],
            main = paste("Boxplot:", param_names[k]),
            ylab = "Τύμή",
            col = "lightblue",
            border = "navy")
    abline(h = mean(samples_matrix[, k]),
           col = "red", lwd = 2, lty = 2)
  }
  dev.off()
}

```

```

}
cat("Boxplots αποθηκεύτηκαν.\n")

bayes_mean <- colMeans(samples_matrix)
bayes_sd    <- apply(samples_matrix, 2, sd)

comparison_table <- data.frame(
  True_Value      = c(true_betas,                2.5^2),
  OLS_Estimate    = c(coef(ols_model),            ols_summary$sigma^2),
  Bayes_Mean      = c(bayes_mean[beta_idx], bayes_mean[sigma2_idx]),
  Bayes_SD        = c(bayes_sd[beta_idx],        bayes_sd[sigma2_idx])
)
rownames(comparison_table) <- c(paste0("beta_", 0:15), "sigma2")

cat("--- Gelman-Rubin Diagnostic ---\n")
print(gelman.diag(samples, multivariate = FALSE))

cat("\n--- Comparison Table ---\n")

print(round(comparison_table, 4))

```

Από τη συγκριτική ανάλυση των αποτελεσμάτων μεταξύ της κλασικής (OLS) και της Μπεϋζιανής προσέγγισης (JAGS), προκύπτουν τα ακόλουθα βασικά στατιστικά συμπεράσματα:

Πίνακας 1: Συγκριτική παρουσίαση εκτιμήσεων: Πραγματικές Τιμές, OLS και Μπεϋζιανή Προσέγγιση (JAGS).

| Παράμετρος   | True Value | OLS Estimate | Bayes Mean | Bayes SD |
|--------------|------------|--------------|------------|----------|
| $\beta_0$    | 4.00       | 3.8450       | 3.8412     | 0.3137   |
| $\beta_1$    | 2.00       | 1.9553       | 1.9601     | 0.3515   |
| $\beta_2$    | 0.00       | -0.6980      | -0.6866    | 0.4279   |
| $\beta_3$    | 0.00       | -0.0515      | -0.0361    | 0.5449   |
| $\beta_4$    | 0.00       | -1.2789      | -1.2585    | 0.6728   |
| $\beta_5$    | -1.00      | -2.1373      | -2.1075    | 0.9955   |
| $\beta_6$    | 0.00       | 0.9003       | 0.9015     | 0.3267   |
| $\beta_7$    | 1.50       | 0.9908       | 0.9891     | 0.3072   |
| $\beta_8$    | 0.00       | -0.1536      | -0.1535    | 0.3569   |
| $\beta_9$    | 0.00       | 0.5162       | 0.5151     | 0.3151   |
| $\beta_{10}$ | 0.00       | 0.2638       | 0.2675     | 0.3450   |
| $\beta_{11}$ | 1.00       | 0.9855       | 0.9827     | 0.2503   |
| $\beta_{12}$ | 0.00       | -0.1428      | -0.1406    | 0.3225   |
| $\beta_{13}$ | 0.50       | 0.1591       | 0.1531     | 0.3067   |
| $\beta_{14}$ | 0.00       | 0.8400       | 0.8352     | 0.3166   |
| $\beta_{15}$ | 0.00       | 0.4636       | 0.4557     | 0.2797   |
| $\sigma^2$   | 6.25       | 5.0911       | 3.6029     | 0.7485   |

### 1. Εκτιμήσεις των Συντελεστών $\beta$ (Μέσες Τιμές):

Οι Μπεϋζιανές ύστερες μέσες τιμές συμπίπτουν σχεδόν απόλυτα με τις αντίστοιχες εκτιμήσεις ελαχίστων τετραγώνων. Για παράδειγμα, για τη σταθερά  $\beta_0$  υπολογίζεται 3.8412 έναντι 3.8450, ενώ για τον συντελεστή  $\beta_1$  λαμβάνουμε 1.9601 έναντι 1.9553. Η εγγύτητα αυτή δείχνει ότι το κέντρο της ύστερης κατανομής προσδιορίζεται με ακρίβεια και συμφωνεί με την κλασική σημειακή εκτίμηση.

### 2. Αβεβαιότητα Εκτιμήσεων (Bayes SD):

Οι Μπεϋζιανές ύστερες τυπικές αποκλίσεις παρέχουν ένα φυσικό μέτρο αβεβαιότητας για κάθε παράμετρο. Παρατηρείται ότι συντελεστές που επηρεάζονται από πολυσυγγραμμικότητα εμφανίζουν αυξημένο Bayes\_SD, όπως για παράδειγμα ο  $\beta_5$  με Bayes\_SD = 0.9955 και ο  $\beta_4$  με Bayes\_SD = 0.6728, αντανakλώντας την αυξημένη αβεβαιότητα που εισάγει η συσχέτιση μεταξύ των επεξηγηματικών μεταβλητών.

### 3. Εκτίμηση της Διασποράς του Σφάλματος ( $\sigma^2$ ):

Η κλασική μέθοδος OLS οδηγεί σε σημειακή εκτίμηση  $\hat{\sigma}_{OLS}^2 = 5.0911$ , ενώ η Μπεϋζιανή ύστερη μέση τιμή είναι 3.6029. Και οι δύο εκτιμήσεις υποεκτιμούν την αληθινή τιμή  $\sigma^2 = 6.25$ , γεγονός που αποδίδεται στην παρουσία των συσχετισμένων μεταβλητών  $X_{11}-X_{15}$ , οι οποίες απορροφούν τεχνητά μέρος της διακύμανσης του σφάλματος.


Η σύγκλιση των Μπεϋζιανών εκτιμήσεων με τις OLS είναι αναμενόμενη, καθώς χρησιμοποιήθηκε μη πληροφοριακή πρότερη κατανομή για το  $\beta$ , με  $M = 0.0001 \cdot I_{16}$ , δηλαδή πολύ μεγάλη πρότερη διασπορά ( $\propto 10000/\tau$ ). Υπό αυτές τις συνθήκες, η ύστερη κατανομή κυριαρχείται από τα δεδομένα και η Μπεϋζιανή μέθοδος αναπαράγει ουσιαστικά τα αποτελέσματα OLS, προσφέροντας επιπλέον πλήρη χαρακτηρισμό της αβεβαιότητας μέσω της ύστερης κατανομής. Ωστόσο προχωρούμε σε γραφικούς ελέγχους που επιβεβαιώνουν την σύγκλιση του αλγορίθμου.

### Σημείωση Αρίθμησης Παραμέτρων:

Στα διαγράμματα MCMC που ακολουθούν, οι παράμετροι εμφανίζονται με την αρίθμηση του JAGS, η οποία ξεκινά από το 1. Συγκεκριμένα, το `beta[j]` στα γραφήματα αντιστοιχεί στην παράμετρο  $\beta_{j-1}$  του μοντέλου, καθώς ο πρώτος συντελεστής `beta[1]` αντιστοιχεί στη σταθερά  $\beta_0$  (intercept). Η αντιστοιχία παρουσιάζεται συνοπτικά στον παρακάτω πίνακα:

| JAGS    | Μοντέλο   | JAGS     | Μοντέλο      |
|---------|-----------|----------|--------------|
| beta[1] | $\beta_0$ | beta[9]  | $\beta_8$    |
| beta[2] | $\beta_1$ | beta[10] | $\beta_9$    |
| beta[3] | $\beta_2$ | beta[11] | $\beta_{10}$ |
| beta[4] | $\beta_3$ | beta[12] | $\beta_{11}$ |
| beta[5] | $\beta_4$ | beta[13] | $\beta_{12}$ |
| beta[6] | $\beta_5$ | beta[14] | $\beta_{13}$ |
| beta[7] | $\beta_6$ | beta[15] | $\beta_{14}$ |
| beta[8] | $\beta_7$ | beta[16] | $\beta_{15}$ |

Πίνακας 2: Αντιστοιχία αρίθμησης JAGS και παραμέτρων μοντέλου.



Σχήμα 1: Διαγράμματα σύγκλισης (Trace plots) για τους συντελεστές  $\beta_0, \dots, \beta_{15}$  και τη διασπορά  $\sigma^2$ .

### Ερμηνεία Trace Plots (History Plots):

Τα διαγράμματα trace plots απεικονίζουν τις διαδοχικές τιμές κάθε παραμέτρου κατά τη διάρκεια των 10.000 επαναλήψεων του αλγορίθμου MCMC, μετά την περίοδο burn-in των 2.000 επαναλήψεων. Κάθε εικόνα αποτελείται από δύο panels: το αριστερό απεικονίζει την εξέλιξη της αλυσίδας στο χρόνο (trace plot), ενώ το δεξί παρουσιάζει την εκτιμώμενη ύστερη πυκνότητα (kernel density) της πρώτης αλυσίδας (Chain 1, μπλε) και τις τιμές δειγματοληψίας της δεύτερης αλυσίδας (Chain 2, κόκκινο).

### Παράμετρος $\beta_3$ (αληθινή τιμή = 0):

Το αριστερό panel εμφανίζει χαρακτηριστική hairy caterpillar μορφή, με τις τιμές να ταλαντώνονται γρήγορα και τυχαία στο διάστημα  $[-2, 2]$  γύρω από το μηδέν, χωρίς εμφανή τάση ή

drift. Αυτό αποτελεί ισχυρή ένδειξη καλής σύγκλισης και επαρκούς ανάμιξης. Το δεξί panel επιβεβαιώνει ότι η ύστερη κατανομή είναι συμμετρική και κεντραρισμένη κοντά στο 0, συμφωνώντας με την εκτίμηση του πίνακα ( $\hat{\beta}_3 = -1.2585$ ), η οποία αποκλίνει από το μηδέν λόγω πολυσυγγραμμικότητας.

**Παράμετρος  $\beta_7$  (αληθινή τιμή = 1.5):**

Το trace plot παρουσιάζει σταθερή ταλάντωση στο διάστημα  $[0, 2.3]$  περί την τιμή  $\approx 1.0$ , χωρίς τάση ή παγίδευση. Το δεξί panel αποκαλύπτει μια σαφώς καμπανοειδή ύστερη κατανομή με κορυφή στο  $\approx 1.0$ , αντί της αληθινής τιμής 1.5. Η απόκλιση αυτή οφείλεται στη συσχέτιση της  $X_7$  με τις  $X_{11}-X_{15}$ , οι οποίες «απορροφούν» μέρος της επίδρασής της.

**Παράμετρος  $\beta_{11}$  (αληθινή τιμή = 1.0):**

Η αλυσίδα ταλαντώνεται σταθερά στο  $[0, 2]$  γύρω από 1, με ικανοποιητική ανάμιξη. Το δεξί panel δείχνει κορυφή της ύστερης κατανομής στο 1, γεγονός που επιβεβαιώνει την ακριβή εκτίμηση  $\hat{\beta}_{11} = 0.9827$  του πίνακα. Η παράμετρος αυτή εκτιμάται με σχετικά μικρό Bayes SD = 0.2503, καθώς η  $X_{11}$  δεν επηρεάζεται εξίσου από την πολυσυγγραμμικότητα.

**Παράμετρος  $\beta_{15}$  (αληθινή τιμή = 0):**


Το trace plot δείχνει ταλάντωση στο  $[-0.8, 1.7]$  με κέντρο  $\approx 0.5$ , χωρίς τάση. Το δεξί panel εμφανίζει ύστερη κατανομή με κορυφή στο  $\approx 0.5$ , η οποία αποκλίνει από την αληθινή τιμή 0 ( $\hat{\beta}_{15} = 0.4557$ ). Η απόκλιση αυτή αποδίδεται στη συσχέτιση της  $X_{15}$  με τις υπόλοιπες επεξηγηματικές μεταβλητές.

**Παράμετρος  $\sigma^2$  (αληθινή τιμή = 6.25):**


Το trace plot της διασποράς κινείται στο διάστημα  $[2, 9]$  με έντονες διακυμάνσεις, αλλά χωρίς τάση, υποδηλώνοντας σύγκλιση. Η ύστερη κατανομή (δεξί panel) είναι θετικά ασύμμετρη, όπως αναμένεται για διασπορά, με κορυφή στο  $\approx 3.6$ . Η σημαντική υποεκτίμηση σε σχέση με την αληθινή τιμή 6.25 αποδίδεται στην παρουσία των συσχετισμένων μεταβλητών  $X_{11}-X_{15}$ , οι οποίες απορροφούν τεχνητά μέρος της διακύμανσης του σφάλματος.

**Συνολική Αξιολόγηση:**

Συνολικά, τα trace plots επιβεβαιώνουν ότι ο αλγόριθμος Gibbs Sampling του JAGS συνέκλινε ικανοποιητικά για όλες τις παραμέτρους. Δεν παρατηρείται αργή ανάμιξη, παγίδευση σε τοπικά ελάχιστα ή μη-στασιμότητα. Οι ύστερες κατανομές (δεξί panel) είναι σε όλες τις περιπτώσεις καμπανοειδείς και συμμετρικές (εκτός του  $\sigma^2$ ), επιβεβαιώνοντας την κανονικότητα της ύστερης κατανομής που προκύπτει από τη συζυγή δομή του μοντέλου.




Σχήμα 2: Ύστερες πυκνότητες για τους συντελεστές  $\beta_0$  έως  $\beta_{15}$ .



Σχήμα 3: Ύστερη πυκνότητα για τη διασπορά  $\sigma^2$ .

Οι παραπάνω παρατηρήσεις επιβεβαιώνονται και από τα ξεχωριστά διαγράμματα πυκνότητας (kernel density plots), στα οποία οι εκτιμώμενες ύστερες κατανομές των δύο αλυσίδων ταυτίζονται σχεδόν απόλυτα για όλες τις παραμέτρους, αποτελώντας ισχυρή ένδειξη σύγκλισης του αλγορίθμου.




Σχήμα 4: Διαγράμματα αυτοσυσχέτισης (ACF) για τους συντελεστές  $\beta$ .


### Ερμηνεία Autocorrelation Plots (ACF):

Τα διαγράμματα αυτοσυσχέτισης εξετάζουν την ανεξαρτησία των διαδοχικών δειγμάτων της αλυσίδας Markov. Οι κόκκινες διακεκομμένες γραμμές ορίζουν τα όρια στατιστικά μη σημαντικής αυτοσυσχέτισης.

Παρατηρείται σαφής διαφοροποίηση μεταξύ των παραμέτρων. Οι  $\beta_0, \beta_6, \beta_7, \beta_9$  και  $\sigma^2$  εμφανίζουν ταχεία αποκοπή ήδη από τα πρώτα lags, υποδηλώνοντας εξαιρετική ανάμιξη και ουσιαστικά ανεξάρτητα δείγματα. Αντίθετα, οι  $\beta_1, \beta_2, \beta_3, \beta_4, \beta_5$  και  $\beta_{11}-\beta_{15}$  παρουσιάζουν αργή εκθετική φθορά που εκτείνεται έως και lag 30–50, γεγονός που αποδίδεται στην πολυσυγγραμμικότητα μεταξύ των αντίστοιχων μεταβλητών. Η παράμετρος  $\sigma^2$  συμπεριφέρεται ικανοποιητικά, με αυτοσυσχέτιση που εισέρχεται εντός των ορίων από το lag 3 και έπειτα. Συνολικά, η παρουσία αυτοσυσχέτισης στις επηρεαζόμενες παραμέτρους υποδηλώνει ότι το effective sample size είναι μικρότερο από τις 10.000 επαναλήψεις, χωρίς ωστόσο να θέτει σε αμφιβολία τη σύγκλιση του αλγορίθμου.



Σχήμα 5: Διαγράμματα Running Quantiles για τους συντελεστές  $\beta$ .



Σχήμα 6: Running Quantiles για τη διασπορά  $\sigma^2$ .

### Ερμηνεία Running Quantiles:

Τα διαγράμματα Running Quantiles απεικονίζουν την εξέλιξη των ποσοστημοριών 2.5% (μπλε), 50% (μαύρο) και 97.5% (κόκκινο) της ύστερης κατανομής καθώς ο αλγόριθμος MCMC συλλέγει δείγματα. Η σταθεροποίηση και των τριών γραμμών σε οριζόντια επίπεδα αποτελεί ισχυρή ένδειξη σύγκλισης.

Για τις παραμέτρους  $\beta_0$  και  $\beta_1$ , η σταθεροποίηση επιτυγχάνεται ήδη από τις πρώτες 500–1000 επαναλήψεις, με διάστημα αξιοπιστίας 95% περίπου  $[3.2, 4.4]$  και  $[1.3, 2.5]$  αντίστοιχα. Παρόμοια γρήγορη σύγκλιση παρατηρείται στις  $\beta_6$ ,  $\beta_7$  και  $\sigma^2$ , όπου οι γραμμές σταθεροποιούνται εντός των πρώτων 1000 επαναλήψεων.

Αντίθετα, παράμετροι που επηρεάζονται από πολυσυγγραμμικότητα, όπως οι  $\beta_4$  και  $\beta_5$ , απαιτούν περισσότερες επαναλήψεις ( $\approx 2000$ – $3000$ ) για να σταθεροποιηθούν, με εκτιμώμενη διάμεσο  $\approx -1.3$  και  $\approx -2.1$  αντίστοιχα. Το πλάτος των διαστημάτων αξιοπιστίας για αυτές τις παραμέτρους είναι αισθητά μεγαλύτερο, αντανakλώντας την αυξημένη αβεβαιότητα.

Για τη διασπορά  $\sigma^2$ , το διάστημα 95% σταθεροποιείται περίπου στο  $[2.5, 5.2]$ , με διάμεσο  $\approx 3.5$ , επιβεβαιώνοντας την υποεκτίμηση σε σχέση με την αληθινή τιμή  $\sigma^2 = 6.25$ .

Συνολικά, η σταθεροποίηση όλων των ποσοστημορίων επιβεβαιώνει ότι οι εκτιμήσεις είναι ανεξάρτητες από το αρχικό σημείο εκκίνησης και ότι τα 10.000 δείγματα επαρκούν για αξιόπιστη εκτίμηση της ύστερης κατανομής.

#### **Απόφαση Αφαίρεσης Μεταβλητών Βάσει Θηκογραφημάτων:**


Από την οπτική εξέταση των θηκογραφημάτων, η απόφαση αφαίρεσης βασίζεται στο αν το 0 τέμνει το κεντρικό σώμα (IQR) της ύστερης κατανομής κάθε παραμέτρου.

**Μεταβλητές που διατηρούνται** — το IQR βρίσκεται καθαρά εκτός του 0:


- $X_0$ : IQR  $\approx [3.7, 4.1]$
- $X_1$ : IQR  $\approx [1.7, 2.2]$
- $X_5$ : IQR  $\approx [-2.5, -1.6]$
- $X_6$ : IQR  $\approx [0.7, 1.1]$
- $X_7$ : IQR  $\approx [0.8, 1.2]$ ,
- $X_{11}$ : IQR  $\approx [0.8, 1.1]$
- $X_{14}$ : IQR  $\approx [0.6, 1.0]$

**Μεταβλητές που αφαιρούνται** — το 0 τέμνει ή είναι εντός του IQR:

- $X_2$ : IQR περιέχει αρνητικές τιμές, τα whiskers αγγίζουν το 0
- $X_3$ : IQR  $\approx [-0.3, 0.3]$
- $X_4$ : IQR εκτείνεται και στις δύο πλευρές του 0
- $X_8$ : IQR  $\approx [-0.4, -0.1]$ , τα whiskers διασχίζουν το 0
- $X_9$ : IQR  $\approx [0.3, 0.7]$ , τα whiskers διασχίζουν το 0
- $X_{10}$ : IQR  $\approx [0.1, 0.4]$ , τα whiskers διασχίζουν το 0
- $X_{12}$ : IQR  $\approx [-0.2, 0.1]$
- $X_{13}$ : IQR  $\approx [0.0, 0.3]$
- $X_{15}$ : IQR  $\approx [0.2, 0.6]$ , τα whiskers διασχίζουν το 0



Σχήμα 7: Θηκογράμματα (Boxplots) της ύστερης κατανομής για τους συντελεστές  $\beta_0, \dots, \beta_{15}$ .



Σχήμα 8: Θηκογράφημα για την παράμετρο  $\sigma^2$ .

Η οπτική ανάλυση των boxplots οδηγεί στην αφαίρεση 9 μεταβλητών και τη διατήρηση 7.

Τώρα θα εξετάσουμε αν οι αληθινές τιμές των συντελεστών στο κέντρο των ύστερων κατανομών.

Εξετάζουμε τις παραμέτρους που διατηρήθηκαν στο μοντέλο:

- $\beta_0$  (true = 4.0, Bayes Mean = 3.84): η αληθινή τιμή βρίσκεται εντός του IQR και κοντά στη διάμεσο

- $\beta_1$  (true = 2.0, Bayes Mean = 1.96): η αληθινή τιμή συμπίπτει σχεδόν με τη διάμεσο
- $\beta_5$  (true = -1.0, Bayes Mean = -2.11): η αληθινή τιμή εμπίπτει στα whiskers αλλά όχι στο IQR λόγω πολυσυγγραμμικότητας
- $\beta_6$  (true = 0, Bayes Mean = 0.90): η αληθινή τιμή 0 βρίσκεται εκτός IQR και εκτός whiskers, η κατανομή έχει μετατοπιστεί λόγω πολυσυγγραμμικότητας
- $\beta_7$  (true = 1.5, Bayes Mean = 0.99): η αληθινή τιμή βρίσκεται στο άνω whisker, εκτός IQR λόγω πολυσυγγραμμικότητας
- $\beta_{11}$  (true = 1.0, Bayes Mean = 0.98): η αληθινή τιμή συμπίπτει σχεδόν με τη διάμεσο
- $\beta_{14}$  (true = 0, Bayes Mean = 0.84): ομοίως, η αληθινή τιμή 0 εκτός IQR

Συνολικά, οι αληθινές τιμές βρίσκονται στο κέντρο της ύστερης κατανομής μόνο για τις παραμέτρους  $\beta_0$ ,  $\beta_1$  και  $\beta_{11}$ , οι οποίες δεν επηρεάζονται σημαντικά από πολυσυγγραμμικότητα. Για τις  $\beta_5$  και  $\beta_7$ , η πολυσυγγραμμικότητα μετατοπίζει την ύστερη κατανομή μακριά από την αληθινή τιμή, ενώ για τις  $\beta_6$  και  $\beta_{14}$  η αληθινή τιμή 0 βρίσκεται εκτός της κατανομής εντελώς.

## Ερώτημα Δ

Ο κώδικας που χρησιμοποιήθηκε παρατίθεται παρακάτω:

```
library(mvtnorm)

gibbs_regression <- function(X, Y, M_diag = 0.0001, n_iter = 20000,
                             burn_in = 5000) {
  n          <- nrow(X)
  p_plus_1   <- ncol(X)

  X_mat <- as.matrix(X)
  Y_vec <- as.numeric(Y)

  M <- diag(M_diag, p_plus_1)
  a <- 0.0001
  b <- 0.0001

  XTX      <- t(X_mat) %*% X_mat
  XTY      <- t(X_mat) %*% Y_vec
  V_beta   <- solve(M + XTX)
  beta_hat <- as.numeric(V_beta %*% XTY)

  beta_samples    <- matrix(0, nrow = n_iter, ncol = p_plus_1)
  sigma2_samples <- numeric(n_iter)
  current_sigma2  <- 1.0

  for (t in 1:n_iter) {
```

```

curr_Sigma    <- current_sigma2 * V_beta
current_beta  <- as.numeric(rmvnorm(1, mean = beta_hat,
                                   sigma = curr_Sigma))

beta_samples[t, ] <- current_beta

resid        <- Y_vec - as.numeric(X_mat %*% current_beta)
shape_sig    <- a + n / 2
scale_sig    <- b + 0.5 * sum(resid^2)

current_sigma2 <- 1 / rgamma(1, shape = shape_sig,
                             rate = scale_sig)
sigma2_samples[t] <- current_sigma2
}

keep_idx <- (burn_in + 1):n_iter

return(list(
  beta    = beta_samples[keep_idx, ],
  sigma2  = sigma2_samples[keep_idx]
))
}

set.seed(123)
gibbs_results <- gibbs_regression(X, Y, M_diag = 0.0001,
                                 n_iter = 20000, burn_in = 5000)

gibbs_beta_mean    <- colMeans(gibbs_results$beta)
gibbs_beta_sd      <- apply(gibbs_results$beta, 2, sd)
gibbs_sigma2_mean  <- mean(gibbs_results$sigma2)
gibbs_sigma2_sd    <- sd(gibbs_results$sigma2)

ols_model    <- lm(Y ~ X - 1)
ols_summary  <- summary(ols_model)

comparison_table <- data.frame(
  True_Value    = c(true_betas,          2.5^2),
  OLS_Estimate  = c(coef(ols_model),      ols_summary$sigma^2),
  OLS_SE        = c(ols_summary$coefficients[, 2], NA),
  Gibbs_Mean    = c(gibbs_beta_mean,      gibbs_sigma2_mean),
  Gibbs_SD      = c(gibbs_beta_sd,        gibbs_sigma2_sd)
)
rownames(comparison_table) <- c(paste0("beta_", 0:15), "sigma2")

cat("--- Gibbs Sampler Results ---\n")
print(round(comparison_table, 4))

```

Πίνακας 3: Συγκριτικά αποτελέσματα για όλες τις παραμέτρους: Πραγματικές Τιμές, OLS και Gibbs Sampler.

| Παράμετρος   | True Value | OLS Estimate | OLS SE | Gibbs Mean | Gibbs SD |
|--------------|------------|--------------|--------|------------|----------|
| $\beta_0$    | 4.00       | 3.8450       | 0.3740 | 3.8444     | 0.3857   |
| $\beta_1$    | 2.00       | 1.9553       | 0.4202 | 1.9526     | 0.4307   |
| $\beta_2$    | 0.00       | -0.6980      | 0.5164 | -0.6973    | 0.5272   |
| $\beta_3$    | 0.00       | -0.0515      | 0.6601 | -0.0577    | 0.6852   |
| $\beta_4$    | 0.00       | -1.2789      | 0.8137 | -1.2862    | 0.8419   |
| $\beta_5$    | -1.00      | -2.1373      | 1.2048 | -2.1470    | 1.2406   |
| $\beta_6$    | 0.00       | 0.9003       | 0.3873 | 0.9059     | 0.3981   |
| $\beta_7$    | 1.50       | 0.9908       | 0.3671 | 0.9908     | 0.3802   |
| $\beta_8$    | 0.00       | -0.1536      | 0.4241 | -0.1537    | 0.4344   |
| $\beta_9$    | 0.00       | 0.5162       | 0.3780 | 0.5186     | 0.3901   |
| $\beta_{10}$ | 0.00       | 0.2638       | 0.4091 | 0.2703     | 0.4203   |
| $\beta_{11}$ | 1.00       | 0.9855       | 0.2969 | 0.9829     | 0.3070   |
| $\beta_{12}$ | 0.00       | -0.1428      | 0.3812 | -0.1362    | 0.3907   |
| $\beta_{13}$ | 0.50       | 0.1591       | 0.3730 | 0.1596     | 0.3839   |
| $\beta_{14}$ | 0.00       | 0.8400       | 0.3794 | 0.8411     | 0.3942   |
| $\beta_{15}$ | 0.00       | 0.4636       | 0.3337 | 0.4653     | 0.3432   |
| $\sigma^2$   | 6.25       | 5.0911       | ---    | 5.3951     | 1.3806   |

## Σύγκριση αποτελεσμάτων Gibbs Sampler, OLS και Ερωτήματος B:

### 1. Εκτιμήσεις συντελεστών $\beta$ :

Οι ύστερες μέσες τιμές του Gibbs Sampler συμπίπτουν σχεδόν απόλυτα με τις εκτιμήσεις OLS. Αυτό είναι αναμενόμενο, καθώς το ύστερο κέντρο που προέκυψε αναλυτικά στο Ερώτημα B είναι:

$$\beta_{post} = (M + X^T X)^{-1}(X^T X)\hat{\beta}$$

Με  $M = 0.0001 \cdot I_{16}$  (μη πληροφοριακό prior), ο πίνακας  $M$  είναι αμελητέος σε σχέση με τον  $X^T X$ , οπότε:

$$(M + X^T X)^{-1}(X^T X) \approx (X^T X)^{-1}(X^T X) = I$$

Συνεπώς  $\beta_{post} \approx \hat{\beta}_{OLS}$ , εξηγώντας την πρακτική ταύτιση των εκτιμήσεων. Οι Gibbs Mean τιμές επιβεβαιώνουν πειραματικά αυτή τη θεωρητική σύγκλιση.

### 2. Εκτίμηση διασποράς $\sigma^2$ :

Από το Ερώτημα B, η περιθώρια ύστερη κατανομή του  $\sigma^2$  είναι:

$$\sigma^2 | (y, X) \sim IG \left( \frac{n}{2} + a, b + \frac{s^2}{2} + \frac{\hat{\beta}^T (M^{-1} + (X^T X)^{-1})^{-1} \hat{\beta}}{2} \right)$$

Η θεωρητική μέση τιμή μιας  $IG(\alpha, b)$  κατανομής είναι  $b/(\alpha - 1)$ , με:

$$\alpha^* = \frac{n}{2} + a = \frac{50}{2} + 0.0001 = 25.0001$$

Ο Gibbs Sampler εκτιμά  $\hat{\sigma}_{Gibbs}^2 = 5.3951$ , έναντι  $\hat{\sigma}_{OLS}^2 = 5.0911$ . Η Μπεϋζιανή εκτίμηση είναι ελαφρώς υψηλότερη διότι ο όρος  $\frac{\hat{\beta}^T (M^{-1} + (X^T X)^{-1})^{-1} \hat{\beta}}{2}$  προσθέτει επιπλέον πληροφορία στην

παράμετρο κλίμακας της IG κατανομής. Και οι δύο εκτιμήσεις υποεκτιμούν την αληθινή τιμή  $\sigma^2 = 6.25$ , αποτέλεσμα που αποδίδεται στην πολυσυγγραμμικότητα των δεδομένων.

### 3. Τυπικές αποκλίσεις :

Τα Gibbs SD είναι ελαφρώς μεγαλύτερα από τα αντίστοιχα OLS SE για όλες τις παραμέτρους, γεγονός που αντικατοπτρίζει τη φύση της Μπεϋζιανής προσέγγισης: το Gibbs SD αποτυπώνει την πλήρη αβεβαιότητα της ύστερης κατανομής, ενώ το OLS SE βασίζεται σε ασυμπτωτικές προσεγγίσεις. Η διαφορά παραμένει μικρή λόγω της μη πληροφοριακής prior.

## Άσκηση 2

Έστω  $X_i$  η τυχαία μεταβλητή που εκφράζει τον αριθμό των σφαλμάτων κατά την  $i$ -οστή ημέρα ( $i = 1, 2, \dots, n$ ). Υποθέτουμε ότι ο αριθμός των σφαλμάτων ακολουθεί την κατανομή Poisson με άγνωστη παράμετρο ρυθμού  $\lambda > 0$ , δηλαδή:

$$X_i \mid \lambda \sim \text{Poisson}(\lambda)$$

Θεωρούμε τυχαίο δείγμα μεγέθους  $n = 10$  ημερών, για το οποίο το συνολικό άθροισμα των παρατηρηθέντων σφαλμάτων ισούται με:

$$Y = \sum_{i=1}^{10} X_i = 35$$

Λόγω της ανεξαρτησίας των παρατηρήσεων, το άθροισμα τυχαίων μεταβλητών Poisson ακολουθεί επίσης κατανομή Poisson, με παράμετρο ίση με το άθροισμα των επιμέρους παραμέτρων. Συνεπώς, το επαρκές στατιστικό  $Y$  του μοντέλου ακολουθεί την κατανομή:

$$Y \mid \lambda \sim \text{Poisson}(n\lambda) \implies Y \mid \lambda \sim \text{Poisson}(10\lambda)$$

Η πιθανοφάνεια του επαρκούς στατιστικού, δεδομένης της παρατηρηθείσας τιμής  $y = 35$ , διαμορφώνεται ως εξής:

$$P(Y = y \mid \lambda) = \frac{e^{-n\lambda}(n\lambda)^y}{y!} = \frac{e^{-10\lambda}(10\lambda)^{35}}{35!}$$

## Ερώτημα Α

Επιθυμούμε να διεξάγουμε τον Μπεϋζιανό έλεγχο των ακόλουθων στατιστικών υποθέσεων:

$$H_0 : \lambda = 2$$

$$H_1 : \lambda \neq 2$$

Για τη σύγκριση των δύο υποθέσεων κατά Bayes, απαιτείται ο προσδιορισμός της περιθώριας πιθανοφάνειας για κάθε μία από αυτές.

Υπό τη μηδενική υπόθεση  $H_0$ , η παράμετρος  $\lambda$  είναι σταθερή και λαμβάνει μία μοναδική τιμή ( $\lambda = 2$ ). Καθώς δεν υφίσταται αβεβαιότητα, η πρότερη κατανομή εκφυλίζεται σε ένα σημείο. Συνεπώς, η περιθώρια πιθανοφάνεια προκύπτει άμεσα από την αντικατάσταση της τιμής  $\lambda = 2$  στη συνάρτηση πιθανοφάνειας του επαρκούς στατιστικού:

$$m_0(y) = P(Y = y \mid \lambda = 2) = \frac{e^{-10(2)}(10 \cdot 2)^{35}}{35!} = \frac{e^{-20} \cdot 20^{35}}{35!}$$

Κάτω από την εναλλακτική υπόθεση  $H_1$ , ορίζεται ότι η παράμετρος  $\lambda$  ακολουθεί a-priori κατανομή  $\text{Gamma}(\alpha = 2, \beta = 1)$ . Η συνάρτηση πυκνότητας πιθανότητας της κατανομής αυτής είναι:

$$\pi_1(\lambda) = \frac{\beta^\alpha}{\Gamma(\alpha)} \lambda^{\alpha-1} e^{-\beta\lambda} = \frac{1^2}{\Gamma(2)} \lambda^{2-1} e^{-1 \cdot \lambda} = \lambda e^{-\lambda}$$

Η επιλογή της πρότερης κατανομής  $\lambda \sim \text{Gamma}(\alpha = 2, \beta = 1)$  αντιπροσωπεύει ασθενή πεποίθηση ότι ο ρυθμός  $\lambda$  κυμαίνεται γύρω από την τιμή 2 (μηδενική υπόθεση) διότι η μέση τιμή  $E[\lambda] = \frac{\alpha}{\beta} = \frac{2}{1} = 2$ , η οποία συμπίπτει με την τιμή της  $H_0$ , εκφράζει την αρχική πεποίθηση ότι ο ρυθμός σφαλμάτων κυμαίνεται γύρω από το 2 ενώ η διασπορά  $\text{Var}[\lambda] = \frac{\alpha}{\beta^2} = \frac{2}{1} = 2$  είναι σχετικά μεγάλη σε σχέση με τη μέση τιμή ( $\text{CV} = \frac{\sqrt{2}}{2} \approx 0.71$ ). Δηλαδή, η κατανομή είναι διάχυτη και επιτρέπει ευρύ φάσμα τιμών για το  $\lambda$ , υποδηλώνοντας ασθενή πεποίθηση.

Υπό την  $H_1$ , η παράμετρος  $\lambda$  είναι άγνωστη, οπότε η περιθώρια πιθανοφάνεια προκύπτει:

$$m_1(y) = \int_0^\infty P(Y = y \mid \lambda) \pi_1(\lambda) d\lambda$$

Αντικαθιστώντας τις δύο συναρτήσεις, λαμβάνουμε:

$$m_1(y) = \int_0^\infty \left( \frac{e^{-n\lambda} (n\lambda)^y}{y!} \right) \cdot \left( \frac{\beta^\alpha}{\Gamma(\alpha)} \lambda^{\alpha-1} e^{-\beta\lambda} \right) d\lambda$$

Εξάγοντας τις σταθερές ποσότητες εκτός του τελεστή ολοκλήρωσης και ομαδοποιώντας τις δυνάμεις του  $\lambda$  καθώς και τους εκθετικούς όρους, έχουμε:

$$m_1(y) = \frac{n^y \beta^\alpha}{y! \Gamma(\alpha)} \int_0^\infty \lambda^{(y+\alpha)-1} e^{-(n+\beta)\lambda} d\lambda$$

Το ορισμένο ολοκλήρωμα αναγνωρίζεται ως ο πυρήνας μιας νέας κατανομής  $\text{Gamma}(y+\alpha, n+\beta)$ . Εφόσον η σταθερά κανονικοποίησης μιας τέτοιας κατανομής ισούται με το αντίστροφο του ολοκληρώματος του πυρήνα της, προκύπτει αναλυτικά ότι:

$$\int_0^\infty \lambda^{(y+\alpha)-1} e^{-(n+\beta)\lambda} d\lambda = \frac{\Gamma(y+\alpha)}{(n+\beta)^{y+\alpha}}$$

Συνεπώς, η γενική αναλυτική μορφή της περιθώριας πιθανοφάνειας διαμορφώνεται ως:

$$m_1(y) = \frac{n^y \beta^\alpha}{y! \Gamma(\alpha)} \frac{\Gamma(y+\alpha)}{(n+\beta)^{y+\alpha}}$$

Αντικαθιστώντας τις τιμές του προβλήματος  $n = 10, y = 35, \alpha = 2, \beta = 1$  και χρησιμοποιώντας την ιδιότητα  $\Gamma(\alpha) = (\alpha - 1)!$  για ακέραιους, λαμβάνουμε:

$$m_1(35) = \frac{10^{35} \cdot 1^2}{35! \cdot \Gamma(2)} \frac{\Gamma(35+2)}{(10+1)^{35+2}} = \frac{10^{35}}{35! \cdot 1!} \frac{\Gamma(37)}{11^{37}}$$

Λόγω της ιδιότητας της συνάρτησης Γάμμα, ισχύει  $\Gamma(37) = 36! = 36 \cdot 35!$ . Αντικαθιστώντας, οι όροι απλοποιούνται κομψά:

$$m_1(35) = \frac{10^{35} \cdot 36 \cdot 35!}{35! \cdot 11^{37}} = \frac{36 \cdot 10^{35}}{11^{37}}$$

Ο παράγοντας Bayes  $BF_{10}$  υπέρ της εναλλακτικής υπόθεσης  $H_1$  ορίζεται ως ο λόγος των δύο περιθωρίων πιθανοφανειών:

$$BF_{10} = \frac{m_1(y)}{m_0(y)}$$

Αντικαθιστούμε τα εκφράσματα των  $m_1(y)$  και  $m_0(y)$  διατηρώντας προσωρινά το 35! για την πλήρη απλοποίηση του παρονομαστή:

$$BF_{10} = \frac{\frac{36 \cdot 10^{35}}{11^{37}}}{\frac{e^{-20} \cdot 20^{35}}{35!}} = \frac{35! \cdot 36 \cdot 10^{35}}{11^{37} \cdot e^{-20} \cdot 20^{35}} = \frac{36!}{11^{37} \cdot e^{-20} \cdot 2^{35}}$$

Ο Ύστερος Λόγος των Υποθέσεων (Posterior Odds -  $PO_{10}$ ) συνδέεται με τον παράγοντα Bayes μέσω της σχέσης:

$$PO_{10} = BF_{10} \times \frac{P(H_1)}{P(H_0)}$$

Καθώς θεωρούμε a-priori ισοπίθανες τις δύο υποθέσεις, ο λόγος των πρότερων πιθανοτήτων ισούται με τη μονάδα. Επομένως, ο ύστερος λόγος ταυτίζεται με τον παράγοντα Bayes:

$$PO_{10} = BF_{10}$$

Για τον ακριβή υπολογισμό της παραπάνω έκφρασης και την αποφυγή σφαλμάτων υπερχειλίσης, χρησιμοποιήθηκε το παρακάτω απόσπασμα κώδικα στο περιβάλλον της R:

```
# 1. Υπολογισμός σε λογαριθμική κλίμακα
log_BF10 <- lfactorial(36) + 20 - 37 * log(11) - 35 * log(2)

# 2. Επαναφορά στην κανονική κλίμακα
BF10 <- exp(log_BF10)
cat("Η τιμή του Bayes Factor (BF10) είναι:", BF10, "\n")
```

Ο υπολογισμός αυτός κατέληξε στην τιμή:

$$\ln(BF_{10}) \approx 2.737 \implies BF_{10} = e^{2.737} \approx 15.45$$

Η υπολογισθείσα τιμή του Παράγοντα Bayes ( $BF_{10} = 15.45$ ) καταδεικνύει ότι τα παρατηρούμενα δεδομένα είναι περίπου 15.5 φορές πιο πιθανό να προκύψουν εφόσον ισχύει η εναλλακτική υπόθεση ( $H_1$ ) σε σύγκριση με τη μηδενική υπόθεση ( $H_0$ ). Βάσει της κλίμακας του Jeffreys, η τιμή αυτή παρέχει ισχυρή στατιστική ένδειξη υπέρ της  $H_1$ .

## Ερώτημα Β

**Ύστερη Κατανομή της παραμέτρου  $\lambda$  |  $y$ :**

Η ύστερη κατανομή είναι ανάλογη του γινομένου της συνάρτησης πιθανοφάνειας των δεδομένων και της πρότερης κατανομής. Για δείγμα  $n = 10$  ημερών από  $\text{Poisson}(\lambda)$  με άθροισμα παρατηρήσεων  $y = 35$ , η πιθανοφάνεια είναι  $\ell(\lambda | y) \propto e^{-10\lambda} \lambda^{35}$ . Η πρότερη κατανομή, υπό την  $H_1$ , είναι η  $\text{Gamma}(\alpha = 2, \beta = 1)$ , με πυκνότητα  $\pi(\lambda) \propto \lambda^{2-1} e^{-1 \cdot \lambda}$ .

Πολλαπλασιάζοντας αυτούς τους δύο όρους, προκύπτει ο πυρήνας της ύστερης κατανομής:

$$\pi(\lambda | y) \propto (e^{-10\lambda} \lambda^{35}) \cdot (\lambda^1 e^{-\lambda}) = \lambda^{36} e^{-11\lambda}$$

Αναγνωρίζουμε ότι η έκφραση αυτή αποτελεί τον πυρήνα μιας κατανομής Gamma με παραμέτρους  $\alpha_{post} = 35 + 2 = 37$  και  $\beta_{post} = 10 + 1 = 11$ . Συνεπώς:

$$\lambda | y \sim \text{Gamma}(37, 11)$$

Υπολογίζουμε την εκ των υστέρων προβλεπτική κατανομή με ολοκλήρωση της παραμέτρου  $\lambda$  στο πεδίο ορισμού της:

$$f(x_{11} | y) = \int_0^\infty f(x_{11} | \lambda) \pi(\lambda | y) d\lambda$$

Αντικαθιστώντας τη συνάρτηση πιθανότητας Poisson για το  $x_{11}$  και την πυκνότητα της Gamma(37, 11) για το  $\lambda$ , λαμβάνουμε:

$$f(x_{11} | y) = \int_0^\infty \left( \frac{e^{-\lambda} \lambda^{x_{11}}}{x_{11}!} \right) \left( \frac{11^{37}}{\Gamma(37)} \lambda^{36} e^{-11\lambda} \right) d\lambda$$

Ομαδοποιώντας τους όρους ως προς τη μεταβλητή ολοκλήρωσης  $\lambda$ :

$$f(x_{11} | y) = \frac{11^{37}}{x_{11}! \cdot \Gamma(37)} \int_0^\infty \lambda^{x_{11}+36} e^{-12\lambda} d\lambda$$

Το ορισμένο ολοκλήρωμα αποτελεί τον πυρήνα μιας Gamma( $x_{11} + 37, 12$ ), άρα η τιμή του ταυτίζεται με το αντίστροφο της σταθεράς κανονικοποίησής της, δηλαδή ίση με  $\frac{\Gamma(x_{11}+37)}{12^{x_{11}+37}}$ . Αντικαθιστώντας πίσω στην εξίσωση:

$$f(x_{11} | y) = \frac{\Gamma(x_{11} + 37)}{x_{11}! \cdot \Gamma(37)} \frac{11^{37}}{12^{x_{11}+37}} = \binom{x_{11} + 37 - 1}{x_{11}} \left( \frac{11}{12} \right)^{37} \left( \frac{1}{12} \right)^{x_{11}}$$

Η τελική αυτή μορφή αποδεικνύει αναλυτικά ότι η ύστερη προβλεπτική κατανομή είναι μια Αρνητική Διωνυμική:

$$x_{11} | y \sim \text{NegBin} \left( r = 37, p = \frac{11}{12} \right)$$

### Μπεϋζιανή Προσέγγιση (Αρνητική Διωνυμική):

Υπολογίζουμε τα εξής:

$$E(x_{11} | y) = E(\lambda | y) = \frac{\alpha_{post}}{\beta_{post}} = \frac{37}{11} \approx 3.364$$

$$\text{Var}(x_{11} | y) = E(\lambda | y) + \text{Var}(\lambda | y) = \frac{37}{11} + \frac{37}{11^2} = \frac{444}{121} \approx 3.669$$

### Κλασική Προσέγγιση:

Στην κλασική στατιστική, η παράμετρος  $\lambda$  εκτιμάται σημειακά από τον Εκτιμητή Μέγιστης Πιθανοφάνειας (MLE). Για δείγμα Poisson, η εκτίμηση είναι  $\hat{\lambda} = \bar{x} = \frac{35}{10} = 3.5$ . Η προβλεπτική κατανομή υποθέτει ότι η παράμετρος είναι γνωστή και σταθερή, άρα  $x_{11} \sim \text{Poisson}(3.5)$ .

$$E_{class}(x_{11}) = \hat{\lambda} = 3.500$$

$$\text{Var}_{class}(x_{11}) = \hat{\lambda} = 3.500$$

### Παρατηρήσεις:

- Η Μπεϋζιανή αναμενόμενη τιμή (3.364) είναι ελαφρώς μικρότερη από την κλασική (3.500). Αυτό συμβαίνει διότι η Μπεϋζιανή εκτίμηση λειτουργεί ως ένας σταθμισμένος μέσος μεταξύ των δεδομένων ( $MLE = 3.5$ ) και της πρότερης κατανομής (η οποία είχε κέντρο το 2). Τα δεδομένα "μετακινήθηκαν" ελαφρώς προς την a-priori πεποιθήση.
- Η Μπεϋζιανή διασπορά (3.669) είναι μεγαλύτερη από την κλασική διασπορά (3.500). Το γεγονός αυτό εξηγείται επειδή η κλασική στατιστική ενσωματώνει αποκλειστικά τον εγγενή θόρυβο του μοντέλου (Poisson διασπορά), αντιμετωπίζοντας την παράμετρο  $\lambda$  ως απόλυτα βέβαιη. Αντίθετα, η Μπεϋζιανή προσέγγιση είναι πιο ρεαλιστική, καθώς προσθέτει στη συνολική αβεβαιότητα και το σφάλμα εκτίμησης της ίδιας της παραμέτρου (τον όρο  $Var(\lambda | y)$ ).

### Υστερη πιθανότητα η 11<sup>η</sup> παρατήρηση να έχει τιμή άνω του 5

Ο υπολογισμός απλοποιείται μέσω του συμπληρωματικού ενδεχομένου:

$$P(x_{11} > 5 | y) = 1 - P(x_{11} \leq 5 | y) = 1 - \sum_{x=0}^5 f(x | y)$$

Αντικαθιστώντας τη συνάρτηση πιθανότητας της Αρνητικής Διωνυμικής που αναπτύχθηκε νωρίτερα:

$$P(x_{11} \leq 5 | y) = \sum_{x=0}^5 \binom{x+36}{x} \left(\frac{11}{12}\right)^{37} \left(\frac{1}{12}\right)^x \approx 0.8647$$

Επομένως, η ζητούμενη τελική πιθανότητα είναι:

$$P(x_{11} > 5 | y) = 1 - 0.8647 = \mathbf{0.1353} \quad (\text{ή } 13.53\%)$$

## Άσκηση 3

### Περιγραφή του Συνόλου Δεδομένων και των Μεταβλητών

Για την εμπειρική εφαρμογή του Μπεϋζιανού μοντέλου, χρησιμοποιείται το πραγματικό σύνολο δεδομένων «Sales of summer clothes in E-commerce Wish», το οποίο έχει αντληθεί από την πλατφόρμα Kaggle (<https://www.kaggle.com/datasets/thedevastator/summer-products-sales-performance>).

Το συγκεκριμένο dataset περιλαμβάνει ιστορικά στοιχεία πωλήσεων, αξιολογήσεις και χαρακτηριστικά προϊόντων από το ηλεκτρονικό εμπόριο της πλατφόρμας Wish. Για τους σκοπούς της στατιστικής μας ανάλυσης, απομονώνονται και ορίζονται οι εξής μεταβλητές:

#### 1. Εξαρτημένη Μεταβλητή:

Ως εξαρτημένη μεταβλητή ορίζεται η `uses_ad_boosts` (Χρήση Διαφήμισης). Πρόκειται για μια δυαδική (binary) μεταβλητή που καταγράφει αν ο πωλητής πλήρωσε για την προώθηση του συγκεκριμένου ενδύματος μέσω διαφημίσεων. Η μεταβλητή λαμβάνει τις τιμές:

- 1: Το προϊόν προωθήθηκε με πληρωμένη διαφήμιση (ad share).
- 0: Το προϊόν αναρτήθηκε και διακινήθηκε αποκλειστικά οργανικά.

## 2. Ανεξάρτητη Μεταβλητή:

Ως ανεξάρτητη μεταβλητή (παράγοντας κατηγοριοποίησης) χρησιμοποιούνται δύο δυαδικές στήλες του dataset, `badge_product_quality` και `badge_local_product`, οι οποίες υποδηλώνουν αντίστοιχα αν ένα προϊόν φέρει σήμα ποιότητας ή αν ο πωλητής έχει αναγνωριστεί ως αξιόπιστος τοπικός έμπορος. Και οι δύο στήλες λαμβάνουν τιμές 0 (απουσία σήματος) ή 1 (παρουσία σήματος). Βάσει αυτών, κατασκευάζεται μια νέα κατηγορική μεταβλητή `badge_category` με τρεις αμοιβαία αποκλειόμενες κατηγορίες, σύμφωνα με την ακόλουθη προτεραιότητα:

- Excellent Quality Badge (`badge_product_quality = 1`): Προϊόντα που φέρουν σήμα κορυφαίας ποιότητας βάσει των κριτικών των καταναλωτών.
- Top Merchant Badge (`badge_local_product = 1` και `badge_product_quality = 0`): Προϊόντα πωλητών που έχουν αναγνωριστεί ως αξιόπιστοι τοπικοί έμποροι της πλατφόρμας, χωρίς να φέρουν ταυτόχρονα σήμα ποιότητας.
- No Badge (`badge_product_quality = 0` και `badge_local_product = 0`): Προϊόντα χωρίς κανένα ειδικό σήμα.

Διαχωρίζουμε λοιπόν τα διαθέσιμα προϊόντα σε τρεις διακριτές κατηγορίες βάσει του σήματος (`badge`) που διαθέτουν. Έστω  $\theta_j$  η πιθανότητα ένα προϊόν της κατηγορίας  $j$  να έχει προωθηθεί μέσω πληρωμένης διαφήμισης, όπου:

- $j = 1$ : Κανένα σήμα (No Badge)
- $j = 2$ : Κορυφαία ποιότητα (Excellent Quality Badge)
- $j = 3$ : Αξιόπιστος πωλητής (Top Merchant Badge)

Σε αντίστοιχη ανάλυση προηγούμενου έτους στην ίδια πλατφόρμα, εξετάστηκε ένα δείγμα 50 προϊόντων της κατηγορίας  $j=3$ . Από αυτά, παρατηρήθηκε ότι τα 40 είχαν χρησιμοποιήσει υπηρεσίες διαφήμισης (ad shares), ενώ τα 10 είχαν αποκλειστικά οργανική απήχηση. Επομένως θα χρησιμοποιήσουμε ως πρότερη κατανομή είναι η  $\text{Beta}(\alpha, \beta)$ , όπου οι υπερπαραμέτροι ερμηνεύονται άμεσα ως:

- $\alpha$ : Αριθμός ιστορικών «επιτυχιών» (προϊόντα με διαφήμιση) = 40
- $\beta$ : Αριθμός ιστορικών «αποτυχιών» (οργανικά προϊόντα) =  $50 - 40 = 10$

Επομένως, η ιστορική πληροφορία μοντελοποιείται μέσω της ακόλουθης πληροφοριακής πρότερης κατανομής:

$$\theta_3 \sim \text{Beta}(40, 10)$$

Η κατανομή αυτή εκφράζει την a-priori πεποίθηση ότι η πιθανότητα διαφήμισης για τους Top Merchants ανέρχεται κατά μέσο όρο σε  $\frac{40}{40+10} = 80\%$ , ενσωματώνοντας παράλληλα έναν σχετικά υψηλό βαθμό βεβαιότητας λόγω του μεγέθους του ιστορικού δείγματος.

Για τις κατηγορίες  $j = 1$  (No Badge) και  $j = 2$  (Excellent Quality Badge), ελλείψει ιστορικών στοιχείων, εκφράζουμε πλήρη αρχική άγνοια. Αυτό επιτυγχάνεται με τη χρήση της Ομοιόμορφης Κατανομής, η οποία αποτελεί ειδική περίπτωση της κατανομής Beta και αποδίδει ίση a-priori πιθανότητα σε κάθε δυνατή τιμή του  $\theta$  στο διάστημα  $(0, 1)$ :

$$\theta_1 \sim \text{Beta}(1, 1)$$

$$\theta_2 \sim \text{Beta}(1, 1)$$

Οι κατανομές αυτές λειτουργούν ως μη-πληροφοριακές (non-informative / diffuse priors), επιτρέποντας στα τρέχοντα παρατηρούμενα δεδομένα να καθορίσουν σχεδόν εξολοκλήρου την ύστερη κατανομή για τις δύο αυτές κατηγορίες ρούχων.

## Προεπεξεργασία Δεδομένων και Κατασκευή Διανυσμάτων

Στο στάδιο αυτό, πραγματοποιείται η προεπεξεργασία των πρωτογενών στοιχείων του dataset στο περιβάλλον της γλώσσας R. Πρωταρχικός στόχος είναι η εξακρίβωση του συνολικού πλήθους των προϊόντων ( $n_j$ ) που ανήκουν σε κάθε μία από τις τρεις υπό μελέτη κατηγορίες σήματος, καθώς και ο προσδιορισμός του πλήθους εκείνων που προωθήθηκαν μέσω πληρωμένης διαφήμισης ( $y_j$ ).

Με την αυτοματοποιημένη αυτή διαδικασία, αποφεύγεται η χειροκίνητη εισαγωγή των συχνοτήτων και κατασκευάζονται άμεσα τα διανύσματα δεδομένων που είναι απαραίτητα για την τροφοδότηση του Μπεϋζιανού μοντέλου στον αλγόριθμο MCMC του προγράμματος JAGS. Ο κώδικας της προεπεξεργασίας παρατίθεται αναλυτικά παρακάτω:

```
library(dplyr)
wish_data      <-      read.csv("summer-products-with-rating-and-
performance_2020-08.csv")
summary_table <- wish_data %>%
  mutate(
    badge_category = case_when(
      badge_product_quality == 1 ~ "Excellent Quality",
      badge_local_product == 1 ~ "Top Merchant",
      TRUE ~ "No Badge"
    )
  ) %>%
  group_by(badge_category) %>%
  summarise(
    n_total = n(),
    y_ad = sum(uses_ad_boosts == 1, na.rm = TRUE)
  ) %>%
  arrange(badge_category)
print(summary_table)
```

Στον Πίνακα 4 παρουσιάζονται συγκεντρωτικά τα αποτελέσματα της προεπεξεργασίας των δεδομένων από το σύνολο δεδομένων της Wish. Τα στοιχεία αυτά προέκυψαν αυτόματα από την εκτέλεση του κώδικα της R και αποτυπώνουν τη διανομή των προϊόντων ανά κατηγορία σήματος καθώς και τη συχνότητα χρήσης πληρωμένης διαφήμισης.

Ο παρακάτω κώδικας ορίζει το Μπεϋζιανό μοντέλο, τροφοδοτεί τα διανύσματα των δεδομένων και εκτελεί την προσομοίωση, αντλώντας τυχαία δείγματα από τις ύστερες κατανομές των παραμέτρων  $\theta_j$ .

Πίνακας 4: Συχνότητες εμφάνισης και χρήση πληρωμένης διαφήμισης ανά κατηγορία σήματος στο σύνολο δεδομένων Wish.

| Κατηγορία Σήματος<br>( <b>badge_category</b> ) | Συνολικό Πλήθος<br>( <b>n_total</b> ) | Πλήθος Διαφημίσεων<br>( <b>y_ad</b> ) | Ποσοστό Διαφήμισης<br>(%) |
|------------------------------------------------|---------------------------------------|---------------------------------------|---------------------------|
| Excellent Quality                              | 117                                   | 51                                    | 43.59%                    |
| No Badge                                       | 1433                                  | 616                                   | 42.99%                    |
| Top Merchant                                   | 23                                    | 14                                    | 60.87%                    |
| <b>Σύνολο</b>                                  | 1573                                  | 681                                   | 43.29%                    |

```
library(R2jags)

model_code <- "
model {
  for (i in 1:3) {
    y[i] ~ dbin(theta[i], n[i])
  }
  theta[1] ~ dbeta(1, 1)      # No Badge
  theta[2] ~ dbeta(1, 1)      # Excellent Quality
  theta[3] ~ dbeta(40, 10)    # Top Merchant
}
"

writeLines(model_code, "wish_model.jags")

jags_data <- list(
  n = c(1433, 117, 23),
  y = c(616, 51, 14)
)

jags_inits <- function() { list(theta = c(0.5, 0.5, 0.5)) }
jags_params <- c("theta")

set.seed(123)
jags_fit <- jags(
  data = jags_data,
  inits = jags_inits,
  parameters.to.save = jags_params,
  model.file = "wish_model.jags",
  n.chains = 3,
  n.iter = 20000,
  n.burnin = 5000,
  n.thin = 2
)
print(jags_fit)
```

Πίνακας 5: Ύστερες εκτιμήσεις παραμέτρων  $\theta_j$  (πιθανότητα χρήσης διαφήμισης) μέσω JAGS.

| Παράμετρος | Κατηγορία Σήματος | Ύστερη Μέση Τιμή (mu . vect) | Τυπική Απόκλιση (sd) | 95% Διάστημα Αξιοπιστίας | Δείκτης $\hat{R}$ (Rhat) | Ενεργό Δείγμα (n . eff) |
|------------|-------------------|------------------------------|----------------------|--------------------------|--------------------------|-------------------------|
| $\theta_1$ | No Badge          | 0.430                        | 0.013                | [0.405, 0.455]           | 1.001                    | 18000                   |
| $\theta_2$ | Excellent Quality | 0.437                        | 0.046                | [0.349, 0.527]           | 1.001                    | 6900                    |
| $\theta_3$ | Top Merchant      | 0.739                        | 0.051                | [0.632, 0.832]           | 1.001                    | 13000                   |

Από την τελική Μπεϋζιανή ανάλυση προκύπτει με σαφήνεια ότι η στρατηγική προώθησης των προϊόντων στην πλατφόρμα Wish δεν είναι ενιαία, αλλά εξαρτάται άμεσα από τα χαρακτηριστικά και την αξιοπιστία του πωλητή:

- **Απλοί και Υψηλά Αξιολογημένοι Έμποροι:** Οι πωλητές χωρίς σήμα (No Badge) καθώς και εκείνοι με προϊόντα υψηλής αξιολόγησης (Excellent Quality) επιλέγουν να διαφημίσουν τα προϊόντα τους σε ένα σταθερό ποσοστό κοντά στο 43%.
- **Έμπιστοι Πωλητές (Top Merchants):** Διαφοροποιούνται πλήρως από τον ανταγωνισμό, παρουσιάζοντας μια εξαιρετικά υψηλή εκ των υστέρων πιθανότητα χρήσης διαφήμισης (73.9%).

Το εύρημα αυτό αποδεικνύει ότι οι κορυφαίοι έμποροι της πλατφόρμας επενδύουν πολύ πιο επιθετικά σε πληρωμένα εργαλεία marketing (ad boosts) προκειμένου να διατηρήσουν τον υψηλό όγκο πωλήσεών τους, να ενισχύσουν την ορατότητά τους και να διασφαλίσουν την κυρίαρχη θέση τους στην ηλεκτρονική αγορά.

### Διαγνωστικοί Έλεγχοι

Για να διασφαλιστεί η αξιοπιστία των Μπεϋζιανών εκτιμήσεων, πραγματοποιήθηκαν διαγνωστικοί έλεγχοι σύγκλισης των παραγόμενων Μαρκοβιανών αλυσίδων, χρησιμοποιώντας το πακέτο coda. Ο κώδικας για την παραγωγή των διαγνωστικών γραφημάτων παρατίθεται παρακάτω:

```
library(coda)


mcmc_samples <- as.mcmc(jags_fit)
png("1_Trace_and_Density_Plots.png", width = 800, height = 600)
plot(mcmc_samples)
dev.off()

geweke_results <- geweke.diag(mcmc_samples)
print(geweke_results)
png("2_Geweke_Diagnostic_Plot.png", width = 800, height = 500)
geweke.plot(mcmc_samples)
dev.off()


gelman_values <- gelman.diag(mcmc_samples)
print(gelman_values)
png("3_Gelman_Rubin_Plot.png", width = 800, height = 500)
```

```
gelman.plot(mcmc_samples)
dev.off()
```


```
heidel_results <- heidel.diag(mcmc_samples)
print(heidel_results)
png("4_Autocorrelation_Plots.png", width = 800, height = 600)
autocorr.plot(mcmc_samples)
dev.off()
```




Σχήμα 9: Διαγράμματα Ίχνους και Πυκνότητας



Σχήμα 10: Διαγράμματα Geweke



Σχήμα 11: Διαγράμματα Gelman-Rubin



Σχήμα 12: Διαγράμματα Αυτοσυσχέτισης

- **Διαγράμματα Ίχνους** Απεικονίζεται η πορεία των τριών διαφορετικών αλυσίδων Markov για κάθε παράμετρο, καθώς και για τη deviance του μοντέλου. Παρατηρείται ότι οι αλυσίδες αλληλοκαλύπτονται πλήρως και κινούνται γύρω από έναν σταθερό μέσο όρο, χωρίς να παρουσιάζουν ανοδικές ή καθοδικές τάσεις. Το γεγονός αυτό αποδεικνύει ότι οι αλυσίδες έχουν εισέλθει στη στάσιμη κατανομή τους. Το διάγραμμα ίχνους της deviance επιβεβαιώνει επιπλέον τη σταθερότητα της συνολικής προσαρμογής του μοντέλου.
- **Διαγράμματα Πυκνότητας** Απεικονίζουν την εκτιμώμενη ύστερη συνάρτηση πυκνότητας πιθανότητας. Οι καμπύλες είναι απόλυτα ομαλές και μονοκόρυφες (unimodal). Εδώ επιβεβαιώνεται οπτικά η διαφοροποίηση των εκτιμήσεων: οι κορυφές των  $\theta_1$  και  $\theta_2$  εντοπίζονται γύρω στο  $0.43 - 0.44$ , ενώ η κορυφή του  $\theta_3$  έχει μετατοπιστεί ξεκάθαρα προς τα δεξιά, συγκεντρώνοντας τη μάζα της γύρω από την τιμή  $0.74$ .
- **Διαγράμματα Geweke** Στο γράφημα εμφανίζονται οι τιμές των  $Z$ -scores για κάθε παράμετρο και για κάθε μία από τις 3 αλυσίδες ξεχωριστά. Οι οριζόντιες διακεκομμένες γραμμές αντιπροσωπεύουν τα κρίσιμα όρια  $[-1.96, 1.96]$ . Η πλειοψηφία των σημείων βρίσκεται εντός των ορίων, υποδηλώνοντας στασιμότητα. Σημειώνεται ότι ο δείκτης  $Z$ -score της  $\theta_1$  στην αλυσίδα 3 εμφανίζεται οριακά εκτός ορίων ( $\approx -3$ ). Ωστόσο, πρόκειται για μεμονωμένο εύρημα σε ένα μόνο τμήμα μίας εκ των τριών αλυσίδων και δεν επηρεάζει τα συνολικά συμπεράσματα σύγκλισης, τα οποία επιβεβαιώνονται από τους υπόλοιπους διαγνωστικούς ελέγχους.
- **Διαγράμματα Gelman-Rubin**

Το κριτήριο αυτό συγκρίνει τη διασπορά μεταξύ των τριών αλυσίδων με τη διασπορά εντός της κάθε αλυσίδας. Στα παραγόμενα διαγράμματα απεικονίζονται η διάμεσος (median - μαύρη συνεχής γραμμή) και το άνω όριο του 97.5% (κόκκινη διακεκομμένη γραμμή) του δείκτη. Ήδη από τις πρώτες επαναλήψεις μετά την περίοδο προσαρμογής (burn-in, περίπου στην επανάληψη 5000-6000), και οι δύο γραμμές κατέρχονται και σταθεροποιούνται απόλυτα στην τιμή 1.0. Δεδομένου ότι δεν ξεπερνούν ποτέ το αυστηρό κρίσιμο όριο του 1.1, επιβεβαιώνεται η πλήρης και επιτυχής σύγκλιση της διαδικασίας προσομοίωσης MCMC. Αξίζει να σημειωθεί ότι για τις παραμέτρους  $\theta_2$  και  $\theta_3$ , ο δείκτης ξεκινά από  $\approx 1.04$  στις πρώτες επαναλήψεις μετά το burn-in, και κατέρχεται ταχύτατα στην τιμή 1.0, επιβεβαιώνοντας την πλήρη σύγκλιση.

- **Διαγράμματα αυτοσυσχέτισης** Για τις παραμέτρους  $\theta_1$  και  $\theta_2$ , η αυτοσυσχέτιση είναι μηδενική ήδη από το Lag 1. Για την παράμετρο  $\theta_3$  (όπου είχαμε την πληροφοριακή Prior), υπάρχει μια πολύ μικρή αρχική αυτοσυσχέτιση στο Lag 1 (κάτω από 0.1), η οποία όμως μηδενίζεται αμέσως στο Lag 5. Αυτή η ακαριαία πτώση στο μηδέν δείχνει ότι τα δείγματα που κρατήσαμε είναι ανεξάρτητα μεταξύ τους, πράγμα που σημαίνει ότι η αλυσίδα εξερευνά τον χώρο ταχύτατα και το thinning = 2 λειτούργησε άψογα.

Πίνακας 6: Συγκριτική παρουσίαση εκτιμήσεων: Κλασική Στατιστική (MLE) και Μπεϋζιανή Προσέγγιση (JAGS).

| Κατηγορία Σήματος    | Μέγεθος Δείγματος ( $n_j$ ) | Επιτυχίες ( $y_j$ ) | Κλασική Εκτίμηση (MLE) | 95% Διάστημα Εμπιστοσύνης (Wald) | Μπεϋζιανή Μέση Τιμή (Mean) | 95% Διάστημα Αξιοπιστίας |
|----------------------|-----------------------------|---------------------|------------------------|----------------------------------|----------------------------|--------------------------|
| 1. No Badge          | 1433                        | 616                 | 43.0% (0.4299)         | [40.4%, 45.5%]                   | 43.0% (0.430)              | [40.5%, 45.5%]           |
| 2. Excellent Quality | 117                         | 51                  | 43.6% (0.4359)         | [34.6%, 52.6%]                   | 43.7% (0.437)              | [34.9%, 52.7%]           |
| 3. Top Merchant      | 23                          | 14                  | 60.9% (0.6087)         | [40.9%, 80.8%]                   | 73.9% (0.739)              | [63.2%, 83.2%]           |

#### A. Συμπεριφορά απουσία πληροφορίας (Κατηγορίες 1 & 2)

Για τις κατηγορίες «No Badge» και «Excellent Quality», όπου επιλέχθηκε η μη-πληροφοριακή πρότερη κατανομή  $\text{Beta}(1, 1)$ , παρατηρούμε ότι οι Μπεϋζιανές εκ των υστέρων μέσες τιμές (43.0% και 43.7%) ταυτίζονται με τους κλασικούς συχνοτικούς εκτιμητές μέγιστης πιθανοφάνειας (MLE) (43.0% και 43.6%). Ταυτόχρονα, τα 95% Μπεϋζιανά Διαστήματα Αξιοπιστίας συμπίπτουν σχεδόν πλήρως με τα κλασικά Διαστήματα Εμπιστοσύνης. Επομένως όταν δεν εισάγουμε εξωτερική πληροφορία στο μοντέλο, η Μπεϋζιανή ανάλυση επιτρέπει στο τρέχον δείγμα να καθορίσει εξολοκλήρου το αποτέλεσμα, οδηγώντας σε αριθμητική σύγκλιση με την κλασική στατιστική.

#### B. Συμπεριφορά με πρότερη πληροφορία (Κατηγορία 3)

Στην κατηγορία «Top Merchant», η κλασική στατιστική υπολογίζει ένα ποσοστό διαφήμισης 60.9%, βασιζόμενη αποκλειστικά στις 23 παρατηρήσεις του δείγματος. Αντίθετα, η Μπεϋζιανή εκτίμηση μετατοπίζεται σημαντικά προς τα πάνω, δίνοντας εκ των υστέρων μέση τιμή 73.9%. Στο σημείο αυτό, βλέπουμε ότι η εκ των υστέρων κατανομή αποτελεί έναν μαθηματικό συμβιβασμό ανάμεσα στην πληροφορία του τρέχοντος δείγματος (60.9%) και την πληροφορία της πρότερης κατανομής  $\text{Beta}(40, 10)$ , η οποία αντανakλούσε μια ιστορική πεποίθηση ύψους 80%. Επειδή το τρέχον δείγμα είναι πολύ μικρό ( $n_3 = 23$ ), η κλασική στατιστική παράγει μια εκτίμηση με τεράστια αβεβαιότητα, καθώς το διάστημα εμπιστοσύνης εκτείνεται από το 40.9% έως

το 80.8%. Η Μπεϋζιανή προσέγγιση διορθώνει την εκτίμηση προς την ιστορική πραγματικότητα και καταφέρνει να μειώσει δραστικά την αβεβαιότητα, προσφέροντας ένα πολύ πιο σταθερό και αξιόπιστο Διάστημα Αξιοπιστίας ([63.2%, 83.2%]).

## Άσκηση 4

### Αναλυτική Εύρεση της Jeffreys Prior για το $\lambda$

Η πρότερη κατανομή κατά Jeffreys (Jeffreys prior) βασίζεται στην πληροφορία του Fisher και ορίζεται ως η τετραγωνική ρίζα της ορίζουσάς της:

$$p(\lambda) \propto \sqrt{I(\lambda)}$$

Έστω μια τυχαία παρατήρηση  $Y$  από την κατανομή  $\text{Poisson}(\lambda)$  με συνάρτηση πιθανότητας:

$$f(y | \lambda) = \frac{e^{-\lambda} \lambda^y}{y!}$$

Λογαριθμίζοντας τη συνάρτηση πιθανότητας για μία παρατήρηση, λαμβάνουμε:

$$\ln f(y | \lambda) = -\lambda + y \ln(\lambda) - \ln(y!)$$

Παραγωγίζουμε ως προς τη μεταβλητή ενδιαφέροντος  $\lambda$  για να προσδιορίσουμε τη συνάρτηση σκορ (score function):

$$\frac{\partial}{\partial \lambda} \ln f(y | \lambda) = -1 + \frac{y}{\lambda}$$

Υπολογίζουμε τη δεύτερη μερική παράγωγο ως προς  $\lambda$ :

$$\frac{\partial^2}{\partial \lambda^2} \ln f(y | \lambda) = -\frac{y}{\lambda^2}$$

Η πληροφορία Fisher για μία μεμονωμένη παρατήρηση ορίζεται ως η αναμενόμενη τιμή της αρνητικής δεύτερης παραγώγου:

$$I(\lambda) = -E \left[ \frac{\partial^2}{\partial \lambda^2} \ln f(Y | \lambda) \right] = -E \left[ -\frac{Y}{\lambda^2} \right] = \frac{1}{\lambda^2} E[Y]$$

Επειδή  $Y \sim \text{Poisson}(\lambda)$ , η αναμενόμενη τιμή της τυχαίας μεταβλητής ισούται με τη σταθερά ρυθμού, δηλαδή  $E[Y] = \lambda$ . Αντικαθιστώντας, προκύπτει:

$$I(\lambda) = \frac{1}{\lambda^2} \cdot \lambda = \frac{1}{\lambda}$$

Συνεπώς, για ένα τυχαίο δείγμα  $n$  ανεξάρτητων και ισόνομων παρατηρήσεων, η συνολική πληροφορία Fisher διαμορφώνεται ως:

$$I_n(\lambda) = n \cdot I(\lambda) = \frac{n}{\lambda}$$

Κατά συνέπεια, η Jeffreys prior για την παράμετρο  $\lambda$  ορίζεται ως:

$$p(\lambda) \propto \sqrt{I_n(\lambda)} = \sqrt{\frac{n}{\lambda}} \propto \lambda^{-1/2}, \quad \lambda > 0$$

Σύμφωνα με το θεώρημα του Bayes, η εκ των υστέρων πυκνότητα πιθανότητας είναι ανάλογη του γινομένου της συνάρτησης πιθανοφάνειας επί την πρότερη κατανομή:

$$p(\lambda | \mathbf{y}) \propto L(\lambda | \mathbf{y}) \cdot p(\lambda)$$

Η συνολική συνάρτηση πιθανοφάνειας για το δείγμα παρατηρήσεων  $\mathbf{y} = (y_1, \dots, y_n)$  είναι:

$$L(\lambda | \mathbf{y}) = \prod_{i=1}^n \frac{e^{-\lambda} \lambda^{y_i}}{y_i!} \propto e^{-n\lambda} \lambda^{\sum_{i=1}^n y_i}$$

Πολλαπλασιάζοντας την πιθανοφάνεια του δείγματος με τον πυρήνα της Jeffreys prior, λαμβάνουμε:

$$p(\lambda | \mathbf{y}) \propto \left( e^{-n\lambda} \lambda^{\sum_{i=1}^n y_i} \right) \cdot \lambda^{-1/2} = e^{-n\lambda} \lambda^{\sum_{i=1}^n y_i - 0.5}$$

Ο εκ των υστέρων αυτός πυρήνας αναγνωρίζεται ως ο πυρήνας μιας κατανομής Gamma ( $\alpha^*, \beta^*$ ) με υπερπαραμέτρους:

$$\alpha^* = \sum_{i=1}^n y_i + 0.5, \quad \beta^* = n$$

Συνεπώς, η ύστερη κατανομή κάτω από την πρότερη Jeffreys γράφεται ορθά ως:

$$\lambda | \mathbf{y} \sim \text{Gamma} \left( \alpha^* = \sum_{i=1}^n y_i + 0.5, \beta^* = n \right)$$

Για την εύρεση της ύστερης κατανομής της παραμέτρου  $\lambda$  υπό τη μη ιδιογενή πρότερη κατανομή κατά Jeffreys ( $p(\lambda) \propto \lambda^{-1/2}$ ), αναπτύχθηκε αλγόριθμος προσομοίωσης Metropolis-Hastings (Random Walk). Ο πλήρης κώδικας για την εκτέλεση της αλυσίδας, τον έλεγχο του ποσοστού αποδοχής και την παραγωγή των διαγνωστικών διαγραμμάτων παρατίθεται παρακάτω:

```
set.seed(456)
n <- 10
sum_y <- 35

log_posterior <- function(lambda, n, sum_y) {
  if (lambda <= 0) return(-Inf)
  return(-n * lambda + (sum_y - 0.5) * log(lambda))
}

N_iter <- 20000
lambda_chain <- numeric(N_iter)
lambda_chain[1] <- 1.0

sigma_prop <- 1.65
accepted_samples <- 0

for (t in 2:N_iter) {
  current_lambda <- lambda_chain[t-1]
  proposed_lambda <- rnorm(1, mean = current_lambda,
```

```

                                sd = sigma_prop)
log_alpha <- log_posterior(proposed_lambda, n, sum_y) -
              log_posterior(current_lambda, n, sum_y)
if (log(runif(1)) < log_alpha) {
  lambda_chain[t] <- proposed_lambda
  accepted_samples <- accepted_samples + 1
} else {
  lambda_chain[t] <- current_lambda
}
}

acc_rate <- (accepted_samples / (N_iter - 1)) * 100
cat("Ποσοστό Αποδοχής:", round(acc_rate, 2), "%\n")

burn_in <- 2000
final_chain <- lambda_chain[(burn_in + 1):N_iter]

png("MH_Plots_Corrected_1.png", width = 900, height = 450)
par(mfrow=c(1,2))
hist(final_chain, breaks=40, col="lightblue",
     main="Ιστόγραμμα του λ",
     xlab="λ", probability=TRUE)
lines(density(final_chain), col="darkblue", lwd=2)
plot(lambda_chain, type="l", col="gray40",
     main="Trace Plot του λ",
     xlab="Επαναλήψεις", ylab="λ")
abline(v=burn_in, col="red", lwd=2, lty=2)
dev.off()

ergodic_mean <- cumsum(final_chain) /
               (1:length(final_chain))
png("MH_Plots_Corrected_2.png", width = 900, height = 450)
par(mfrow=c(1,2))
plot(ergodic_mean, type="l", col="darkgreen", lwd=2,
     main="Ergodic Mean Plot",
     xlab="Επαναλήψεις (μετά το burn-in)",
     ylab="Τρεχούσα Μέση")
acf(final_chain,
     main="Διάγραμμα Αυτοσυσχετίσεων (ACF)",
     lag.max=50)
dev.off()

```

Η επιλογή της τυπικής απόκλισης της κατανομής πρότασης ( $\sigma_{prop} = 1.65$ ) στην προγραμματιστική υλοποίηση προσεγγίζει σε μεγάλο βαθμό τη θεωρητικά βέλτιστη τιμή. Σύμφωνα με τη θεωρία των αλγορίθμων τυχαίου περιπάτου (Random Walk Metropolis-Hastings), ο βέλτιστος

προσεγγιστικός κανόνας για την κλιμάκωση της κατανομής εισήγησης ορίζεται ως:

$$\sigma_{prop} \approx \frac{2.38}{\sqrt{d}} \cdot \sigma_{post}$$

όπου  $d$  είναι η διάσταση της παραμέτρου (εδώ  $d = 1$ ) και  $\sigma_{post}$  είναι η τυπική απόκλιση της πραγματικής ύστερης κατανομής-στόχου.


Καθώς αποδείχθηκε αναλυτικά ότι η ύστερη κατανομή είναι η  $\text{Gamma}(\alpha^* = 35.5, \beta^* = 10)$ , η διασπορά της ισούται με  $\frac{\alpha^*}{(\beta^*)^2} = \frac{35.5}{100} = 0.355$ . Επομένως, η τυπική απόκλιση της ύστερης κατανομής είναι:

$$\sigma_{post} = \sqrt{0.355} \approx 0.596$$

Αντικαθιστώντας τις τιμές στον τύπο της βελτιστοποίησης, λαμβάνουμε:

$$\sigma_{prop} \approx \frac{2.38}{\sqrt{1}} \cdot 0.596 \approx \mathbf{1.42}$$

## Διαγνωστικός Έλεγχος των Γραφημάτων



Σχήμα 13: Αριστερά: Ιστόγραμμα συχνотήτων. Δεξιά: Διάγραμμα ίχνους (Trace Plot) ολόκληρης της αλυσίδας με διακεκομμένη γραμμή για το όριο του burn-in.


### 1. Ιστόγραμμα του $\lambda$ (Εικόνα 13, Αριστερά):

Το ιστόγραμμα απεικονίζει τη συχνότητα των προσομοιωμένων τιμών του  $\lambda$  μετά την αφαίρεση της περιόδου προσαρμογής, πάνω στο οποίο έχει προσαρμοστεί η ομαλή μπλε γραμμή της εκ των υστέρων πυκνότητας πιθανότητας (posterior density curve). Το ιστόγραμμα εμφανίζει μια απόλυτα ομαλή, μονοκόρυφη και ελαφρώς δεξιά ασύμμετρη κατανομή, η οποία κεντράρεται γύρω από την εκ των υστέρων μέση τιμή (3.564). Το σχήμα αυτό συμπίπτει απόλυτα με τη θεωρητική μορφή της ύστερης κατανομής  $\text{Gamma}(35.5, 10)$  που υπολογίστηκε αναλυτικά, επιβεβαιώνοντας ότι ο αλγόριθμος Metropolis-Hastings κατάφερε να αναπαράγει με εξαιρετική ακρίβεια την κατανομή-στόχο.

### 2. Trace Plot του $\lambda$ (Εικόνα 13, Δεξιά):

Απεικονίζει την τροχιά και την εξέλιξη της αλυσίδας για το σύνολο των 20.000 επαναλήψεων.

Η κόκκινη κατακόρυφη διακεκομμένη γραμμή προσδιορίζει το σημείο διακοπής του burn-in (2.000 επαναλήψεις). Παρατηρούμε ότι η αλυσίδα ξεκινά από την αυθαίρετη αρχική τιμή  $\lambda^{(1)} = 1.0$ , αλλά συγκλίνει ακαριαία στην περιοχή υψηλής εκ των υστέρων πιθανότητας. Για το υπόλοιπο της προσομοίωσης, η αλυσίδα ταλαντώνεται σταθερά γύρω από τον μέσο όρο χωρίς να εμφανίζει καθοδικές ή ανοδικές τάσεις ή περιόδους εγκλωβισμού, αποτελώντας οπτική ένδειξη καλής ανάμιξης και επιτυχούς σύγκλισης.



Σχήμα 14: Αριστερά: Διάγραμμα εργοδικού μέσου όρου (Ergodic Mean Plot). Δεξιά: Διάγραμμα αυτοσυσχετίσεων (ACF Plot) έως το χρονικό υστέρημα 50.

### 3. Ergodic Mean Plot (Εικόνα 14, Αριστερά):

Καταγράφει την εξέλιξη του μέσου όρου των προσομοιωμένων τιμών του  $\lambda$  καθώς αυξάνονται οι επαναλήψεις μετά την περίοδο burn-in. Το διάγραμμα παρουσιάζει αρχικές διακυμάνσεις κατά τις πρώτες  $\approx 2.000$  επαναλήψεις μετά το burn-in, στη συνέχεια όμως σταθεροποιείται σε οριζόντια πορεία γύρω από την τιμή 3.564, επιβεβαιώνοντας την επάρκεια του συνολικού αριθμού επαναλήψεων. Οι αρχικές διακυμάνσεις υποδηλώνουν ότι η επιλογή burn-in = 2.000 ήταν οριακά επαρκής· σε μελλοντική ανάλυση θα μπορούσε να επεκταθεί σε 5.000 επαναλήψεις για μεγαλύτερη ασφάλεια.

### 4. Διάγραμμα Αυτοσυσχετίσεων - ACF (Εικόνα 14, Δεξιά):

Απεικονίζει τη γραμμική συσχέτιση των τιμών της παραγόμενης αλυσίδας με τον εαυτό τους σε διαφορετικές χρονικές υστερήσεις (Lags). Παρατηρείται αρχική θετική αυτοσυσχέτιση στο Lag 1 ( $\approx 0.60$ ), η οποία φθίνει με εκθετικό ρυθμό και σταθεροποιείται εντός των ορίων τυχαιότητας (μπλε διακεκομμένες γραμμές) μετά το Lag 10. Η παρουσία αυτοσυσχέτισης στα πρώτα lags είναι αναμενόμενη για αλγόριθμο Random Walk MH και δεν θέτει σε αμφιβολία τη σύγκλιση, η οποία επιβεβαιώνεται από τα υπόλοιπα διαγνωστικά γραφήματα.

## Στατιστικά Αποτελέσματα και Διάστημα Αξιοπιστίας

Από το τελικό δείγμα των 18.000 προσομοιωμένων τιμών της παραμέτρου  $\lambda$ , το οποίο προέκυψε μετά την αφαίρεση της περιόδου προσαρμογής (burn-in), εξήχθησαν τα ακόλουθα περιγραφικά στατιστικά στοιχεία:

Πίνακας 7: Περιγραφικά στατιστικά στοιχεία και 95% συμμετρικό Μπεϋζιανό διάστημα αξιοπιστίας από την κονσόλα της R.

| Στατιστικός Δείκτης             | Τιμή (MCMC)      |
|---------------------------------|------------------|
| Ελάχιστο (Min.)                 | 1.7620           |
| 1ο Τεταρτημόριο (1st Qu.)       | 3.1430           |
| Διάμεσος (Median)               | 3.5310           |
| Εκ των Υστέρων Μέση Τιμή (Mean) | 3.5640           |
| 3ο Τεταρτημόριο (3rd Qu.)       | 3.9550           |
| Μέγιστο (Max.)                  | 6.1420           |
| Τυπική Απόκλιση (SD)            | 0.6043           |
| 95% Διάστημα Αξιοπιστίας        | [2.4841, 4.8481] |

Το 95% Μπεϋζιανό διάστημα αξιοπιστίας για την παράμετρο  $\lambda$  υπολογίστηκε απευθείας από τα ποσοστιαία σημεία 2.5% και 97.5% της εμπειρικής ύστερης κατανομής:

$$CI_{\text{Bayes}} = [2.484, 4.848]$$

Επομένως, με βάση τα παρατηρηθέντα δεδομένα και την πρότερη γνώση κατά Jeffreys, η ύστερη πιθανότητα η πραγματική τιμή της παραμέτρου ρυθμού  $\lambda$  να περιέχεται στο διάστημα  $[2.484, 4.848]$  είναι ίση ακριβώς με 95%. Το γεγονός ότι το διάστημα αυτό είναι σχετικά στενό, παρά τη χρήση μη πληροφοριακής πρότερης κατανομής, οφείλεται στο ότι η πληροφορία του τρέχοντος δείγματος ( $y = 35$  σφάλματα σε  $n = 10$  ημέρες) είναι επαρκής για να προσδιορίσει με ικανοποιητική ακρίβεια τη θέση της παραμέτρου, συγκεντρώνοντας τη μάζα της ύστερης πιθανότητας γύρω από την εκ των υστέρων μέση τιμή (3.564).